LUCRARE DE DISERTAȚIE

Îndrumător proiect/Coordonator ştiinţific,
Conf. dr. mat. Simona MOLDOVANU

Absolvent,
Florin-Octavian ROBU

Galaţi
2026

SPECIALIZAREA: MASTER - TEHNOLOGII INFORMATICE AVANSATE

MULTIMODAL LEARNING PENTRU CLASIFICAREA ȘI PREDICȚIA EMOȚIILOR

Coordonator ştiinţific,
Conf. dr. mat. Simona MOLDOVANU

Absolvent,
Florin-Octavian ROBU

Galaţi
2026

Mulţumiri

Doresc să îmi exprim recunoştinţa faţă de doamna ***Conf. dr. mat. Simona MOLDOVANU****, pentru coordonarea ştiinţifică, îndrumarea constantă şi pentru încrederea acordată în dezvoltarea acestei teme de cercetare pe parcursul elaborării lucrării de disertaţie.*

Cercetările efectuate în perioada masteratului au fost valorificate prin două contribuţii ştiinţifice.

Lucrarea „*Machine Learning-Based Analysis of Celestial Objects Using the SDSS17 Dataset*", prezentată la ISEEE 2025 – 9th International Symposium of Electrical and Electronics Engineering şi publicată în IEEE Xplore, a fost elaborată în coautorat cu Conf. univ. dr. ing. Dan MUNTEANU.

Articolul „*Multi-Class Emotion Classification through Visual Content Analysis Using Deep Learning Techniques*", acceptat spre publicare în System Theory, Control and Computing Journal, a fost elaborat în coautorat cu Conf. dr. mat. Simona MOLDOVANU şi Ioana-Diana MOLDOVANU.

Rezumat

Prezenta lucrare propune o abordare multimodală pentru recunoaşterea stărilor afective în contextul tehnologic al anului 2026, frecvent menţionat în literatura de specialitate drept „anul multimodal" — un moment de maturitate al sistemelor capabile să proceseze nativ informaţii vizuale şi auditive. Lucrarea dezvoltă şi evaluează un sistem hibrid care integrează modalităţile vizuală şi auditivă prin arhitecturi complementare şi strategii de fuziune cu complexitate crescătoare, validate atât în condiţii controlate cât şi pe date externe nevăzute în antrenare.

Fundamentul experimental constă în utilizarea setului de date multimodal CREMA-D (7.442 clipuri, 91 actori, 6 clase emoţionale) pentru antrenare, cu partiţionare la nivel de actor pentru prevenirea data leakage, şi a setului RAVDESS (1.056 mostre, 24 actori) pentru evaluarea cross-dataset a capacităţii de generalizare.

Pe componenta vizuală sunt evaluate două arhitecturi antrenate pe CREMA-D la rezoluţiile 64×64 şi 128×128 pixeli, în format color şi grayscale: un model CNN antrenat de la zero obţine până la 57,63% acurateţe, iar modelul EfficientNet-B0 fine-tuned obţine până la 50,40%. Pe componenta auditivă, clasificatorul Random Forest pe vectori MFCC obţine 44,81%, SVM obţine 48,34%, iar modelul Wav2Vec2 fine-tuned obţine 68,00%, confirmat cu 66,00% în evaluarea cross-dataset pe RAVDESS.

Sunt implementate şi evaluate trei strategii de fuziune multimodală pe 24 de configuraţii vizual–audio: Late Fusion cu ponderi fixe, Late Fusion adaptivă bazată pe entropia Shannon şi Model-Level Fusion prin meta-clasificatori Logistic Regression şi Random Forest. Cel mai bun rezultat obţinut este de 77,56% acurateţe (CNN_128_color + Wav2Vec2 + Model Fusion RF), faţă de 68,00% al celui mai bun model unimodal. Evaluarea cross-dataset pe RAVDESS confirmă superioritatea generalizării sistemelor bazate pe EfficientNet faţă de CNN antrenat de la zero, EfficientNetB0_128_color + Wav2Vec2 obţinând 70,64% pe date nevăzute în antrenare.

Lucrarea abordează explicit asimetria temporală dintre fluxurile audio şi vizuale prin extragerea unui cadru reprezentativ poziţionat la o treime din durata totală a clipului, interval identificat experimental ca superior faţă de zona mediană. Este demonstrată, de asemenea, fezabilitatea deployment-ului pe Raspberry Pi, configuraţia EfficientNetB0 + Wav2Vec2 cu Model Fusion RF fiind selectată ca soluţie principală pentru deployment embedded, datorită capacităţii superioare de generalizare demonstrate în evaluarea cross-dataset.

CUPRINS

Introducere 1

Capitolul 1. Stadiul actual al cercetării 3

1.1. Evoluţia affective computing: de la sisteme unimodale la multimodale 3

1.2. Modele de reprezentare a emoţiilor: discrete şi dimensionale 4

1.3. Seturi de date benchmark: seturi controlate şi naturale 4

1.4. Provocări cheie în recunoaşterea multimodală a emoţiilor 5

Capitolul 2. Baze de date utilizate şi preprocesare 6

2.1. CREMA-D 6

2.2. RAVDESS — set de date pentru evaluare multimodală 7

2.3. Reguli de mapare a etichetelor 8

Capitolul 3. Metodologie propusă 10

3.1. Extracţia trăsăturilor 10

3.2. Componenta vizuală: Arhitectură CNN şi fine tuning pe EfficientNet-B0 10

3.3. Componenta auditivă: Random Forest, SVM şi fine tuning pe Wav2Vec2 11

3.4. Alinierea şi sincronizarea multimodală 12

3.5. Strategii de fuziune multimodală 12

3.5.1. Late Fusion cu ponderi fixe 13

3.5.2. Late Fusion adaptivă bazată pe entropia Shannon 14

3.5.3. Model-Level Fusion 16

3.5.4. Early Fusion — motivarea excluderii 17

3.6. Strategia de evaluare cross-dataset 18

Capitolul 4 – Rezultate experimentale 19

4.1. Configuraţia experimentală 19

4.2. Rezultate modele unimodale 19

4.2.1. Modele vizuale pe CREMA-D 19

4.2.2. Modele audio pe CREMA-D 24

4.2.3. Analiză comparativă — toate modelele unimodale 27

4.3. Rezultate fuziune multimodală pe CREMA-D 28

4.4. Evaluare cross-dataset pe RAVDESS 31

Capitolul 5. Implementare hardware şi software 34

5.1. Stack tehnologic 34

5.2. Configuraţia hardware 34
5.3. Pipeline de inferenţă şi consideraţii pentru deployment embedded 35
5.4. Implementarea aplicaţiei pe platforma Raspberry Pi 4 37
Capitolul 6 — Discuţii şi direcţii viitoare 39
6.1. Sinteza contribuţiilor 39
6.2. Limitări şi lecţii învăţate 40
6.3. Consideraţii etice 40
6.4. Direcţii viitoare 41
Concluzii 42
Bilanţ 42
Bibliografie 44

LISTA FIGURILOR

Figura 1. Exemple reprezentative din setul CREMA-D 7
Figura 2. Exemple reprezentative din setul RAVDESS 8
Figura 3. Arhitectura Late Fusion 13
Figura 4. Strategie adaptivă Late Fusion bazată pe estimarea entropiei 15
Figura 5. Comportament adaptiv al fuziunii bazate pe entropie - scenarii ilustrative 15
Figura 6. Fuziune Model-Level Fusion prin meta-clasificator 16
Figura 7. Arhitectura Early Fusion 17
Figura 8. Grafice de antrenare şi matrice de confuzie — CNN 64×64 21
Figura 9. Grafice de antrenare şi matrice de confuzie — CNN 128×128 22
Figura 10. Grafice de antrenare şi matrice de confuzie — EfficientNet-B0 64×64 24
Figura 11. Grafice de antrenare şi matrice de confuzie - EfficientNet-B0 128×128 24
Figura 12. Matrice de confuzie — Random Forest şi SVM 26
Figura 13. Grafic de antrenare şi matrice de confuzie — Wav2Vec2 fine-tuned 27
Figura 14. Comparaţie F1 per clasă —CNN şi EfficientNet-B0 28
Figura 15. Comparaţie F1 per clasă — modele audio 28
Figura 16. Grafice alpha sweep — combinaţii reprezentative Late Fusion 30
Figura 17. Pipeline de inferenţă multimodală în timp real pe Raspberry Pi 35
Figura 18. Dispozitivul Raspberry Pi 4 cu camera IMX477 şi microfonul USB 37
Figura 19. Captură de ecran a aplicaţiei notebook, cu detecţia emoţiilor în timp real 38

LISTA TABELELOR

Tabelul 1. Rezultate comparative — modele vizuale pe CREMA-D 20
Tabelul 2. F1 per clasă — configuraţii CNN pe CREMA-D 21
Tabelul 3. F1 per clasă — configuraţii EfficientNet-B0 pe CREMA-D 23

Tabelul 4. Rezultate comparative — modele audio 25
Tabelul 5. F1 per clasă — modele audio 26
Tabelul 6. Tabel comparativ complet — toate modelele unimodale 27
Tabelul 7. Rezultate comparative — toate strategiile de fuziune 29
Tabelul 8. Comparaţie acurateţe vizuală CREMA-D vs RAVDESS 31
Tabelul 9. Rezultate evaluare cross-dataset RAVDESS — toate combinaţiile 32
Tabelul 10. Stack tehnologic — antrenare şi deployment 34
Tabelul 11. Configuraţia hardware — antrenare şi deployment 35

INTRODUCERE

Emoţiile umane reprezintă un element esenţial al comunicării şi interacţiunii sociale, influenţând deciziile, relaţiile interpersonale şi modul de colaborare în ecosistemele digitale moderne. Detectarea şi predicţia precisă a stărilor emoţionale au devenit obiective prioritare în domenii precum affective computing (inteligenţa artificială afectivă), interacţiunea om–maşină (HCI), asistenţii virtuali inteligenţi şi sistemele autonome. Tradiţional, aceste sarcini s-au bazat pe o singură modalitate de date – fie expresii faciale extrase din imagini, fie analiza semnalului vocal (prosodie, intonaţie, ritm) – însă limitările inerente fiecărei modalităţi izolate, precum zgomotul ambiental sau ambiguitatea semantică, au restrâns considerabil robusteţea modelelor în condiţii reale de utilizare.

În acest context, multimodal learning (învăţarea multimodală) a apărut ca o paradigmă transformatoare, permiţând integrarea simultană a informaţiilor provenite din surse eterogene pentru obţinerea unor reprezentări mai bogate şi mai fidele ale stărilor afective. Prin mecanisme de fuziune cross-modală, modelele pot compensa limitările unei modalităţi cu avantajele celeilalte, conducând la creşteri semnificative ale acurateţei de clasificare şi ale capacităţii de generalizare a sistemelor.

În sensul prezentei lucrări, multimodal learning reprezintă procesul de integrare şi corelare simultană a informaţiilor provenite din surse diferite, în special date vizuale şi audio, în vederea obţinerii unei reprezentări unificate şi mai robuste a stărilor emoţionale.

Este important de subliniat faptul că metodele de multimodal learning necesită utilizarea unor seturi de date corelate multimodal, în care componentele vizuale şi audio provin din aceeaşi mostră temporală (de exemplu, acelaşi clip video). Această corespondenţă directă între modalităţi este esenţială pentru realizarea corectă a fuziunii, întrucât utilizarea unor surse de date independente sau necorelate ar conduce la modele inconsistente şi la rezultate experimentale neconcludente.

Anul 2026 este descris în literatura de specialitate ca un punct de maturitate al sistemelor multimodale [21], caracterizat de apariţia unor modele capabile să proceseze nativ şi să raţioneze unificat asupra informaţiilor vizuale şi auditive, creând un cadru favorabil avansării cercetării în recunoaşterea automată a stărilor emoţionale.

Prezenta lucrare explorează potenţialul multimodal learning prin dezvoltarea şi evaluarea unor arhitecturi hibride care integrează modalităţi vizuale şi auditive complementare, combinate prin trei strategii de fuziune distincte şi validate atât în condiţii controlate, cât şi pe date externe nevăzute în antrenare (cross-dataset evaluation).

Contribuţiile principale ale lucrării sunt următoarele:

• proiectarea şi antrenarea unei componente vizuale alcătuite din două modele distincte de clasificare a emoţiilor faciale: o arhitectură CNN dezvoltată de la zero şi un model EfficientNet-B0 adaptat prin fine-tuning, evaluate la rezoluţiile 64×64 şi 128×128 pixeli în format color şi grayscale;

• proiectarea și evaluarea unei componente auditive alcătuite din trei modele complementare de recunoaștere a emoțiilor vocale: Random Forest și SVM antrenate pe vectori MFCC, respectiv un model Wav2Vec2 rafinat prin fine-tuning pe semnal audio brut;

• implementarea și analiza comparativă a strategiilor de fuziune multimodală aplicate exhaustiv pe 24 de configurații vizual–audio, incluzând Late Fusion cu ponderi fixe, Late Fusion adaptivă bazată pe entropia Shannon și Model-Level Fusion cu clasificatori Logistic Regression și Random Forest;

• evaluarea capacității de generalizare a sistemului multimodal prin cross-dataset evaluation pe setul RAVDESS, confirmată cu 70,64% acuratețe pentru configurația EfficientNetB0_128_color + Wav2Vec2;

• demonstrarea fezabilității deployment-ului unui sistem multimodal de recunoaștere a emoțiilor pe hardware cu resurse limitate (Raspberry Pi), prin selectarea configurației EfficientNetB0 + Wav2Vec2 cu Model Fusion RF ca soluție principală pentru deployment embedded, datorită capacității superioare de generalizare demonstrate în evaluarea cross-dataset.

Lucrarea este structurată în șase capitole. Capitolul 1 acoperă stadiul actual al cercetării, Capitolul 2 descrie bazele de date utilizate și preprocesarea, Capitolul 3 detaliază metodologia propusă — arhitecturile modelelor vizuale și auditive și strategiile de fuziune multimodală implementate. Capitolul 4 prezintă rezultatele experimentale obținute, inclusiv evaluarea cross-dataset pe RAVDESS. Capitolul 5 descrie implementarea pe Raspberry Pi și considerațiile pentru deployment embedded, iar Capitolul 6 sintetizează contribuțiile lucrării, discută limitările și propune direcții de cercetare viitoare.

CAPITOLUL 1. STADIUL ACTUAL AL CERCETĂRII

Domeniul recunoaşterii automate a emoţiilor (affective computing) a cunoscut o evoluţie semnificativă în ultimele două decenii, trecând de la sisteme unimodale, centrate pe o singură sursă de informaţie (vizuală sau auditivă), către arhitecturi multimodale complexe, susţinute de progresele recente în deep learning şi în modelele capabile să proceseze date eterogene [10], [14]. Această tranziţie a fost determinată de limitările inerente abordărilor unimodale, care se dovedesc fragile în prezenţa zgomotului, a variaţiilor de context sau a ambiguităţilor expresive.

În prezent, cercetarea din acest domeniu se concentrează pe integrarea informaţiilor provenite din mai multe modalităţi, precum expresiile faciale, semnalul vocal şi contextul conversaţional, cu scopul de a obţine reprezentări afective mai robuste şi mai generalizabile. În acest cadru, au fost propuse numeroase strategii de reprezentare a emoţiilor, seturi de date de referinţă (benchmark datasets) şi mecanisme de fuziune, fiecare cu avantaje şi limitări specifice.

Prezentul capitol analizează stadiul actual al cercetării în recunoaşterea emoţiilor, abordând principalele paradigme de modelare a stărilor afective, seturile de date utilizate frecvent în literatură şi provocările metodologice asociate învăţării multimodale, care motivează soluţiile propuse în capitolele următoare.

1.1. Evoluţia affective computing: de la sisteme unimodale la multimodale

Conceptul de affective computing a fost introdus de Rosalind Picard în 1997 [14], primele sisteme dezvoltate în acest domeniu fiind axate exclusiv pe analiza unimodală, fie a expresiilor faciale, fie a semnalelor vocale. Până în anul 2012, majoritatea abordărilor au rămas limitate la o singură modalitate de date, utilizând seturi de date relativ mici, colectate în condiţii controlate, şi metode tradiţionale de învăţare automată. Aceste sisteme prezentau performanţe reduse în scenarii reale, fiind sensibile la factori precum zgomotul ambiental, variaţiile de iluminare şi dependenţa de context [10].

Anul 2012 reprezintă un punct de inflexiune major, odată cu adoptarea pe scară largă a reţelelor neuronale convoluţionale (CNN), catalizată de apariţia arhitecturii AlexNet [9]. Aceasta a demonstrat superioritatea învăţării profunde în extragerea automată a caracteristicilor vizuale relevante, deschizând drumul către utilizarea sistematică a modelelor deep learning în recunoaşterea emoţiilor [10].

Cu toate acestea, limitările inerente ale fiecărei modalităţi izolate au devenit tot mai evidente, accelerând tranziţia către abordări multimodale începând cu anul 2016 [15]. Primele arhitecturi relevante de fuziune cross-modală, precum Multimodal Transformer Networks [6] şi CTNet [11], au permis integrarea eficientă a informaţiilor vizuale şi auditive. Acestea au fost urmate de arhitecturi bazate pe mecanisme de atenţie, cum ar fi MulT [23] (2019), şi de transformere multimodale, exemplificate de MAG-BERT [16] (2020), capabile să modeleze dependenţe complexe între modalităţi.

În paralel, arhitecturi vizuale de înaltă eficienţă, precum familia EfficientNet [22], au optimizat semnificativ raportul dintre acurateţe şi cost computaţional, facilitând integrarea componentei vizuale în sisteme multimodale cu resurse limitate.

Perioada 2023–2026 este caracterizată de emergența modelelor multimodale de mari dimensiuni (MLLMs), care permit integrarea contextuală cross-modală și învățarea few-shot [19]. În acest context, utilizarea tehnicilor de transfer learning, bazate pe modele pre-antrenate pe seturi extinse precum ImageNet, a devenit o practică standard pentru obținerea unor performanțe ridicate, inclusiv pe hardware cu resurse limitate (edge computing).

O analiză sistematică recentă a literaturii [4] evidențiază o orientare dominantă către arhitecturi multimodale în perioada 2024–2025, precum și o extindere a abordărilor trimodale (audio–vizual–text), reflectând maturizarea tehnicilor de fuziune cross-modală și tranziția către sisteme afective mai robuste și mai generalizabile.

1.2. Modele de reprezentare a emoțiilor: discrete și dimensionale

Reprezentarea stărilor emoționale în sistemele de affective computing este structurată în jurul a două paradigme fundamentale: modelele discrete și modelele dimensionale. Alegerea paradigmei de reprezentare influențează direct arhitectura sistemului, tipul de etichetare utilizat și capacitatea de generalizare în scenarii reale.

Modelul discret, propus de Ekman [5], definește un set de emoții de bază – furie, dezgust, frică, fericire, tristețe și surpriză – la care este adesea adăugată starea neutral. Această abordare rămâne dominantă în literatura de specialitate și în multe seturi de date utilizate în domeniu, datorită simplității conceptuale și compatibilității cu etichetarea umană. Principalul dezavantaj al acestui model constă în dificultatea de a reprezenta stări emoționale subtile, tranzitorii sau compuse, care nu pot fi încadrate univoc într-o singură categorie [2].

În contrast, modelul dimensional, introdus de Russell [17] [18], descrie emoțiile într-un spațiu continuu, definit în principal de axele valence (pozitiv–negativ) și arousal (activ–pasiv), uneori extins cu dimensiunea dominance. Avantajul major al acestei paradigme constă în capacitatea de a captura intensitatea și tranzițiile emoționale, fiind adecvată pentru modelarea dinamicii afective. Totuși, etichetarea dimensională este mai subiectivă și mai dificil de exploatat în sarcini clasice de clasificare, ceea ce limitează aplicabilitatea sa directă în sisteme multimodale discrete [2].

În timp ce modelul Ekman oferă o granularitate categorială adecvată clasificării rapide și robuste, modelul Russell permite o reprezentare mai fină a nuanțelor emoționale, aspect esențial în aplicații de monitorizare continuă sau analiză afectivă pe termen lung. Ca urmare, numeroase sisteme moderne adoptă abordări hibride, combinând clasificarea discretă cu predicția dimensională, în special în aplicații de analiză afectivă continuă și interacțiune adaptivă om–mașină.

1.3. Seturi de date benchmark: seturi controlate și naturale

În literatura de specialitate, seturile de date utilizate pentru recunoașterea emoțiilor pot fi grupate în trei categorii principale, în funcție de gradul de control asupra procesului de colectare: seturi controlate, seturi semi-controlate și seturi naturale (in-the-wild).

Seturile controlate, precum CREMA-D [3] și RAVDESS [27], sunt colectate în condiții de laborator și utilizează actori profesioniști care exprimă deliberat stări emoționale

predefinite. Aceste seturi oferă înregistrări de calitate ridicată şi etichetare precisă, fiind caracterizate de zgomot redus şi variabilitate limitată. Ca rezultat, performanţele obţinute de modelele unimodale pe aceste date sunt frecvent ridicate, însă capacitatea de generalizare către scenarii reale este limitată.

Spre deosebire de acestea, seturile naturale (in-the-wild) reflectă variabilitatea reală a mediilor de utilizare, incluzând iluminare neuniformă, posturi faciale naturale, zgomot ambiental şi contexte conversaţionale complexe, introducând provocări suplimentare precum etichetare mai zgomotoasă şi distribuţii dezechilibrate ale claselor.

Prezenta lucrare utilizează exclusiv seturi controlate — CREMA-D pentru antrenarea componentelor vizuală şi auditivă, şi RAVDESS rezervat exclusiv evaluării cross-dataset a capacităţii de generalizare — asigurând condiţii experimentale reproductibile şi comparabile.

1.4. Provocări cheie în recunoaşterea multimodală a emoţiilor

Recunoaşterea multimodală a emoţiilor se confruntă cu o serie de provocări tehnice şi metodologice persistente, care continuă să limiteze robusteţea şi generalizarea sistemelor afective moderne [25]. Una dintre cele mai importante dificultăţi este alinierea modalităţilor, atât din punct de vedere temporal, cât şi semantic.

Alinierea temporală este complicată de decalajele naturale dintre manifestările vizuale şi auditive ale emoţiilor, care pot ajunge la sute de milisecunde între expresiile faciale şi componentele prosodice ale vorbirii [26]. Această asimetrie cross-modală poate conduce la decuplări semantice între semnale, afectând acurateţea mecanismelor de fuziune. Pentru a atenua aceste efecte, literatura propune utilizarea unor mecanisme de sincronizare, precum extragerea cadrelor reprezentative din intervale temporale definite ale clipului, coerente cu dinamica expresiei umane.

Robusteţea sistemelor este afectată suplimentar de zgomotul ambiental, variaţiile de iluminare şi diversitatea culturală, factori care reduc semnificativ performanţa modelelor în scenarii reale [7]. Generalizarea cross-dataset şi cross-cultural rămâne limitată, fiind raportate scăderi substanţiale ale performanţei atunci când modelele antrenate predominant pe date occidentale sunt evaluate pe populaţii şi contexte diferite [8]. În acest context, literatura recentă subliniază importanţa mecanismelor adaptive, capabile să ajusteze contribuţia fiecărei modalităţi în funcţie de calitatea şi fiabilitatea semnalului disponibil [25].

Pe lângă provocările tehnice, consideraţiile etice şi de confidenţialitate reprezintă un pilon esenţial în dezvoltarea sistemelor afective contemporane. Aspecte precum guvernanţa datelor biometrice, atenuarea prejudecăţilor algoritmice (algorithmic bias) şi asigurarea transparenţei în procesarea informaţiilor sensibile sunt critice pentru adoptarea responsabilă a acestor tehnologii [12]. În aplicaţii sensibile, precum sănătatea mintală sau evaluarea performanţei umane, lipsa interpretabilităţii modelelor multimodale amplifică aceste preocupări.

Aceste provocări definesc frontiera actuală a cercetării în recunoaşterea multimodală a emoţiilor şi evidenţiază necesitatea unor soluţii care să combine aliniere robustă, adaptabilitate la zgomot şi consideraţii etice integrate.

CAPITOLUL 2. BAZE DE DATE UTILIZATE ŞI PREPROCESARE

Acest capitol descrie seturile de date utilizate pentru antrenarea şi evaluarea sistemului multimodal de recunoaştere a emoţiilor, precum şi etapele de preprocesare aplicate fiecărei modalităţi. Accentul este pus pe construcţia unui pipeline coerent multimodal, în care datele vizuale şi audio sunt extrase şi utilizate în mod sincron, permiţând învăţarea relaţiilor reale dintre expresia facială şi semnalul vocal.

Este esenţial de subliniat că datele utilizate trebuie să fie corelate la nivel de mostră — componentele vizuală şi auditivă provenind din acelaşi clip video — condiţie fundamentală pentru validitatea experimentală a fuziunii multimodale. Utilizarea unor seturi de date diferite sau necorelate ar conduce la combinaţii nevalide din punct de vedere experimental şi la rezultate neconcludente.

2.1. CREMA-D

În cadrul prezentei lucrări a fost utilizat setul de date CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset) [3], un dataset audio-video care conţine înregistrări multimodale etichetate emoţional. Alegerea acestui set de date este motivată de faptul că oferă simultan informaţie vizuală şi audio pentru fiecare mostră, ceea ce permite aplicarea corectă a tehnicilor de multimodal learning.

Setul de date CREMA-D conţine un total de 7.442 de clipuri video originale, provenite de la 91 de actori (48 bărbaţi şi 43 femei), cu vârste cuprinse între 20 şi 74 de ani, aparţinând unor categorii etnice diverse. Fiecare actor interpretează 12 propoziţii diferite, exprimate folosind una dintre cele şase emoţii fundamentale: anger, disgust, fear, happy, neutral şi sad, fiecare emoţie fiind redată la diferite niveluri de intensitate (low, medium, high şi unspecified).

Un aspect important al datasetului îl reprezintă procesul de etichetare, realizat prin crowdsourcing. Un număr de 2.443 de participanţi au evaluat fiecare clip în funcţie de emoţia percepută şi nivelul acesteia, atât pe baza componentei audio, cât şi a celei vizuale sau a combinaţiei acestora. Aproximativ 95% dintre clipuri beneficiază de cel puţin 7 evaluări independente, ceea ce asigură o consistenţă ridicată a etichetelor şi o reprezentare fidelă a percepţiei emoţionale umane.

În cadrul etapei de preprocesare, a fost realizată o extracţie sincronizată a componentelor vizuală şi audio pentru fiecare mostră. Din fiecare clip video a fost selectat un singur cadru reprezentativ, poziţionat la o treime din durata totală a clipului, poziţie identificată experimental ca oferind expresivitate emoţională superioară faţă de zona mediană, redimensionat la rezoluţiile 64×64 şi 128×128 pixeli, în format color (RGB) şi grayscale, generând configuraţii distincte evaluate comparativ în cadrul experimentelor.

Detectarea feţei în cadrul selectat a fost realizată prin algoritmul Haar Cascade [24], cu un mecanism de fallback pe cadrul complet în cazul eşecului detecţiei, asigurând astfel procesarea tuturor mostrelor fără eliminări.

Componenta audio a fost prelucrată prin extragerea unui set extins de caracteristici, incluzând coeficienţi MFCC (40), derivatele acestora (delta), precum şi alte descrieri spectrale (chroma şi mel-spectrogram) [13], rezultând un vector de caracteristici de

dimensiune totală 300. Această abordare asigură corespondenţa directă între cele două modalităţi şi permite aplicarea corectă a tehnicilor de fuziune multimodală.

Partiţionarea setului de date a fost realizată la nivel de actor, nu de mostră, pentru a preveni data leakage între setul de antrenare şi cel de testare. Actorii 1001–1073 (73 de actori) au fost alocaţi setului de antrenare, iar actorii 1074–1091 (18 actori) setului de testare, rezultând un split de aproximativ 80%/20%, cu 5.967 mostre de antrenare şi 1.475 mostre de testare.

Exemple reprezentative din fiecare clasă emoţională sunt prezentate în Figura 1.



Figura 1. Exemple reprezentative din setul CREMA-D
sursă proprie

2.2. RAVDESS — set de date pentru evaluare multimodală

Evaluarea unui sistem multimodal de recunoaştere a emoţiilor necesită utilizarea unor seturi de date care să includă simultan informaţie vizuală şi audio sincronizată, astfel încât să fie posibilă testarea corectă a strategiilor de fuziune. În acest scop, a fost utilizat setul de date RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song) [27], selectat pentru evaluarea sistemului în condiţii diferite faţă de cele utilizate în etapa de antrenare.

RAVDESS este un dataset audio-vizual de înaltă calitate, care conţine înregistrări realizate cu actori profesionişti în condiţii controlate. Acesta permite studierea expresiilor emoţionale într-un cadru standardizat, fiecare actor interpretând aceleaşi propoziţii cu emoţii diferite şi niveluri variate de intensitate. Componenta multimodală a datasetului oferă corespondenţă directă între expresia facială şi semnalul vocal, ceea ce îl face potrivit pentru evaluarea sistemelor care integrează informaţie din mai multe modalităţi.

În cadrul acestei lucrări au fost utilizaţi toţi cei 24 de actori disponibili (Actor_01–Actor_24), rezultând un set iniţial de 1.440 de înregistrări video. Pentru a asigura compatibilitatea cu setul de date CREMA-D utilizat în etapa de antrenare, au fost eliminate clasele calm (02) şi surprised (08), păstrându-se doar emoţiile comune angry, disgust, fear, happy, neutral şi sad. În urma acestui proces de filtrare, setul final utilizat pentru evaluare conţine 1.056 de mostre multimodale corelate.

Preprocesarea datelor a fost realizată într-o manieră compatibilă cu cea utilizată pentru CREMA-D, pentru a permite compararea directă a rezultatelor. Componenta vizuală a fost extrasă din clipurile video-only (modalitate 02), iar componenta audio din fişierele audio-only corespunzătoare (modalitate 03), asigurând sincronizarea corectă între cele două modalităţi pentru fiecare mostră. Componenta vizuală a fost obţinută prin extragerea unui singur cadru reprezentativ, poziţionat la o treime din durata totală a clipului, redimensionat la rezoluţiile 64×64 şi 128×128 pixeli, în format color (RGB) şi grayscale, identic ca metodologie cu preprocesarea aplicată pe CREMA-D.

Componenta audio a fost procesată utilizând o rată de eşantionare de 16 kHz, fiind extrase caracteristici spectrale complexe, incluzând coeficienţi MFCC (40), derivatele acestora, precum şi reprezentări de tip chroma şi mel-spectrogram [13], rezultând un vector de caracteristici cu dimensiunea totală de 300, identic ca structură cu cel utilizat pentru CREMA-D.

Această procesare asigură o corespondenţă directă între cele două modalităţi, fiecare mostră fiind definită prin asocierea dintre o imagine, un vector de caracteristici audio şi o etichetă emoţională, ceea ce permite aplicarea corectă a metodelor de fuziune multimodală. Distribuţia claselor emoţionale în setul rezultat este echilibrată pentru majoritatea emoţiilor, fiecare dintre clasele angry, disgust, fear, happy şi sad fiind reprezentată prin câte 192 de mostre, în timp ce clasa neutral conţine 96 de mostre.

Prin utilizarea acestui set de date, evaluarea sistemului se realizează într-un scenariu de tip cross-dataset, în care modelele antrenate pe CREMA-D sunt testate pe date diferite, ceea ce permite analiza capacităţii de generalizare a sistemului multimodal dincolo de datele de antrenare.

Exemple reprezentative din fiecare clasă emoţională sunt prezentate în Figura 2.



Figura 2. Exemple reprezentative din setul RAVDESS
sursă proprie

2.3. Reguli de mapare a etichetelor

Pentru a permite utilizarea în comun a seturilor de date CREMA-D şi RAVDESS în cadrul evaluării multimodale, a fost necesară alinierea spaţiilor de etichete emoţionale, întrucât cele două seturi de date definesc distribuţii diferite ale emoţiilor.

Setul de date CREMA-D conţine şase emoţii distincte (angry, disgust, fear, happy, neutral, sad), în timp ce RAVDESS include opt clase emoţionale (neutral, calm, happy, sad, angry, fearful, disgust, surprised). Pentru a asigura compatibilitatea între acestea şi pentru a evita introducerea unor clase inexistente în setul de antrenare, s-a realizat o mapare a etichetelor bazată pe intersecţia celor două seturi.

Astfel, au fost eliminate din RAVDESS clasele calm şi surprised, deoarece acestea nu au corespondent direct în CREMA-D şi ar introduce inconsistenţe în procesul de evaluare. În urma acestei filtrări, a fost obţinut un set comun de şase emoţii, compatibil între cele două seturi de date: angry, disgust, fear, happy, neutral şi sad.

Procesul de mapare a implicat, de asemenea, uniformizarea denumirilor etichetelor, astfel încât etichetele din RAVDESS să corespundă semantic celor din CREMA-D. De exemplu, eticheta fearful din RAVDESS a fost mapată la fear, menţinând consistenţa terminologică între seturi. Această strategie de aliniere este conformă cu practica standard din literatura de specialitate pentru evaluările cross-dataset pe seturi cu spaţii de etichete parţial suprapuse [10].

Strategia de aliniere adoptată asigură că modelele antrenate pe CREMA-D pot fi evaluate corect pe datele din RAVDESS, fără a introduce clase necunoscute sau ambiguităţi semantice, şi permite analiza capacităţii de generalizare a sistemului în scenariul cross-dataset.

CAPITOLUL 3. METODOLOGIE PROPUSĂ

Prezentul capitol detaliază arhitecturile şi strategiile tehnice propuse şi implementate în cadrul lucrării, parcurgând întregul flux computaţional de la preprocesarea semnalelor brute până la mecanismele avansate de fuziune multimodală. Metodologia propusă este concepută special pentru implementarea pe dispozitive cu resurse limitate (edge computing), urmărind un echilibru optim între precizie predictivă, robusteţe în condiţii reale şi eficienţă computaţională necesară rulării în timp real pe platforme embedded precum Raspberry Pi.

Abordarea adoptată este hibridă: fluxurile vizual şi auditiv sunt procesate prin tehnici paralele, optimizate independent pentru a extrage reprezentări afective de nivel înalt. Aceste reprezentări sunt ulterior integrate într-un spaţiu vectorial comun prin mecanisme de fuziune adaptivă. Spre deosebire de sistemele clasice orientate exclusiv către maximizarea acurateţei, metodologia propusă prioritizează robusteţea sistemului în scenarii in-the-wild, unde zgomotul senzorial, variaţiile de iluminare, ocluziile şi condiţiile acustice nefavorabile reprezintă regula, nu excepţia.

3.1. Extracţia trăsăturilor

Procesul de extracţie a trăsăturilor reprezintă etapa fundamentală a sistemului, având rolul de a transforma semnalele brute — flux video şi semnal audio — în reprezentări vectoriale de nivel înalt, capabile să exprime stări afective complexe. Orice pierdere de informaţie în această etapă nu poate fi recuperată ulterior, motiv pentru care extracţia trăsăturilor determină în mod direct calitatea fuziunii multimodale.

În cadrul metodologiei propuse s-a adoptat o abordare hibridă pentru cele două modalităţi, combinând tehnici de deep learning cu metode clasice de machine learning, utilizate atât pentru stabilirea unui baseline solid de performanţă, cât şi pentru interpretabilitate. Metodologia integrează antrenarea de la zero a modelelor dedicate cu tehnici de fine-tuning, asigurând alinierea vectorilor de probabilitate la spaţiul de şase clase emoţionale: angry, disgust, fear, happy, neutral şi sad.

3.2. Componenta vizuală: Arhitectură CNN şi fine tuning pe EfficientNet-B0

Componenta vizuală generează vectorul de probabilitate $P_{vizual} \in \mathbb{R}^6$ prin procesarea cadrelor faciale extrase din clipurile CREMA-D la rezoluţiile de 64×64 şi 128×128 pixeli, în format color şi grayscale, utilizând două modele distincte antrenate pe acelaşi set de date.

Modelul CNN antrenat pe CREMA-D este o reţea neuronală convoluţională proiectată de la zero. Arhitectura este organizată în patru blocuri convoluţionale, fiecare conţinând câte două straturi Conv2D cu filtre de 32, 64, 128 şi 256 de canale, cu activare ReLU şi batch normalization, fiecare bloc urmat de max-pooling şi dropout progresiv (0.25, 0.30, 0.35, 0.40) pentru regularizare. Capul de clasificare include un strat Dense(512) cu Dropout(0.5), urmat de un strat Dense(256) cu Dropout(0.3) şi activare softmax pe şase clase. Dezechilibrul de clase a fost compensat prin ponderi calculate automat prin metoda balanced. Această organizare în blocuri convoluţionale duble este inspirată din arhitectura VGGNet [20], adaptată pentru dimensiunile reduse ale

imaginilor şi constrângerile computaţionale impuse de deployment-ul pe dispozitive embedded.

Modelul EfficientNet-B0 [22], arhitectura de bază din familia EfficientNet propusă de Tan şi Le (2019), este bazată pe principiul scalării compuse — o metodă sistematică de scalare simultană a adâncimii, lăţimii şi rezoluţiei reţelei printr-un coeficient uniform. Arhitectura conţine aproximativ 5,3 milioane de parametri, organizaţi în şapte blocuri principale de tip MBConv (Mobile Inverted Bottleneck Convolution) cu mecanisme de atenţie Squeeze-and-Excitation.

În cadrul lucrării, modelul pre-antrenat pe ImageNet a fost supus unui proces de fine-tuning în două faze pe setul CREMA-D. În Faza 1 (feature extraction), blocurile convoluţionale ale bazei sunt îngheţate, iar capul de clasificare personalizat — Dense(512) → BatchNormalization → Dropout(0.4) → Dense(256) → Dropout(0.3) → Softmax(6) — este antrenat cu un learning rate de 3×10^{-4} şi cosine decay scheduler, utilizând label smoothing de 0.05. În Faza 2 (fine-tuning), blocurile block4–block7 şi stratul top sunt deblocate şi rafinate cu un learning rate redus de 3×10^{-5}, permiţând adaptarea reprezentărilor de nivel înalt la specificul expresiilor faciale emoţionale din CREMA-D. Augmentarea datelor — RandomFlip, RandomRotation, RandomTranslation, RandomZoom şi RandomContrast — este aplicată consistent în ambele faze.

Ambele modele produc la ieşire vectorul $P_{vizual} \in \mathbb{R}^6$, asigurând compatibilitatea directă cu mecanismele de fuziune multimodală. Evaluarea comparativă completă a celor două modele vizuale este prezentată în Capitolul 4.

3.3. Componenta auditivă: Random Forest, SVM şi fine tuning pe Wav2Vec2

Componenta auditivă extrage trăsăturile acustice relevante — prosodie, intonaţie şi ritm vocal — şi generează vectorul de probabilitate $P_{audio} \in \mathbb{R}^6$. Au fost implementate trei abordări complementare, antrenate pe setul CREMA-D.

Clasificatorul Random Forest a fost antrenat pe vectori de caracteristici spectrale de dimensiune 300, compuşi din 40 de coeficienţi MFCC, derivatele delta, reprezentări chroma şi mel-spectrogram extrase cu librosa [13]. Clasificatorul utilizează 2.000 de arbori de decizie cu criteriul entropiei şi ponderi de clasă echilibrate automat.

Clasificatorul SVM cu kernel RBF a fost antrenat pe aceiaşi vectori de caracteristici de dimensiune 300, după normalizare prin StandardScaler, cu parametrii C=10 şi gamma='scale'. Ambii clasificatori produc probabilităţi de clasă prin predict_proba, compatibile cu mecanismele de fuziune.

Modelul Wav2Vec2 fine-tuned valorifică arhitectura wav2vec2-base [1], pre-antrenată pe date extinse de vorbire. Semnalul audio brut este procesat la o rată de eşantionare de 16 kHz, segmentele fiind trunchiate ori completate la o durată maximă de 4 secunde. Media reprezentărilor contextuale pe întreaga înregistrare produce un vector compact utilizat ca input pentru un cap de clasificare personalizat — Dense(512) → BatchNormalization → Dropout(0.4) → Dense(256) → Dropout(0.3) → Softmax(6) — antrenat prin fine-tuning pe setul CREMA-D cu optimizatorul AdamW, learning rate de 2×10^{-5}, warmup scheduler liniar şi gradient clipping la norma 1.0, pe 20 de epoci cu early stopping după 5 epoci fără îmbunătăţire.

Toate cele trei modele produc la ieşire vectorul $P_{audio} \in \mathbb{R}^6$, asigurând compatibilitatea directă cu mecanismele de fuziune multimodală. Deşi Wav2Vec2 fine-tuned oferă reprezentări acustice de nivel înalt datorită pre-antrenării pe date extinse de vorbire, clasificatoarele Random Forest şi SVM prezintă avantaje semnificative din perspectiva eficienţei computaţionale şi a vitezei de inferenţă.

3.4. Alinierea şi sincronizarea multimodală

În cadrul sistemelor multimodale audio-video, una dintre provocările fundamentale constă în alinierea temporală a informaţiilor provenite din surse eterogene. Fluxurile vizual şi auditiv prezintă caracteristici temporale distincte — atât din punct de vedere al frecvenţei de eşantionare, cât şi al modului de reprezentare a informaţiei [26] — iar o sincronizare deficitară între acestea poate conduce la pierderi semnificative de informaţie şi la degradarea performanţei mecanismelor de fuziune.

Componenta vizuală este reprezentată sub forma unei succesiuni discrete de cadre, eşantionate la frecvenţe tipice de 25–30 cadre pe secundă, fiecare cadru surprinzând o stare statică a expresiei faciale. În contrast, componenta auditivă este un semnal continuu, eşantionat la frecvenţe ridicate (de ordinul kHz), care captează variaţii rapide ale intonaţiei, intensităţii şi ritmului vocal. Această diferenţă fundamentală face ca asocierea directă între un cadru video şi un segment audio punctual să fie ambiguă şi, în multe cazuri, incorectă din punct de vedere semantic, întrucât emoţiile nu se manifestă instantaneu, ci pe intervale temporale variabile, rezultând din corelaţii dinamice între expresia facială şi caracteristicile prosodice ale vorbirii.

În cadrul lucrării, sincronizarea dintre fluxurile vizual şi auditiv a fost realizată prin extragerea unui singur cadru reprezentativ, poziţionat la o treime din durata totală a clipului video, poziţie identificată experimental ca oferind expresivitate emoţională superioară faţă de zona mediană. Simultan, întregul semnal audio al aceluiaşi clip este procesat pentru extragerea vectorului de caracteristici spectrale de dimensiune 300. Această strategie asigură că informaţiile vizuale şi auditive supuse fuziunii provin din acelaşi clip şi din acelaşi interval temporal reprezentativ, eliminând riscul corelării unor semnale afective necorelate. Mecanismul este aplicat consistent atât pe setul de antrenare CREMA-D, cât şi pe setul de evaluare RAVDESS, asigurând comparabilitatea directă a rezultatelor obţinute în scenariul cross-dataset.

3.5. Strategii de fuziune multimodală

Fuziunea multimodală constituie componenta centrală a sistemului propus, având rolul de a integra informaţiile eterogene provenite din modalităţile vizuală şi auditivă, în vederea obţinerii unei predicţii emoţionale superioare celei oferite de orice modalitate individuală. Spre deosebire de abordările unimodale, integrarea cross-modală permite compensarea reciprocă a limitărilor inerente fiecărei surse de date — sensibilitatea la iluminare sau ocluzii în cazul imaginilor, respectiv zgomotul ambiental şi variaţiile prosodice în cazul semnalului audio. Provocarea principală a acestei etape constă în gestionarea eficientă a corelaţiilor temporale şi semantice dintre expresiile faciale şi variaţiile prosodice, ţinând cont de asimetria naturală existentă între cele două modalităţi. În cadrul lucrării au fost implementate şi evaluate multiple strategii de

fuziune, de la abordări clasice până la tehnici avansate adaptative şi bazate pe învăţare, permiţând o analiză comparativă riguroasă a compromisurilor dintre acurateţe, robusteţe şi cost computaţional.

În literatura de specialitate [15], [25], strategiile de fuziune multimodală sunt clasificate în funcţie de nivelul la care se realizează integrarea informaţiilor. Early Fusion (Feature-Level Fusion) combină informaţiile la nivel de trăsături brute, înainte de clasificare, permiţând captarea corelaţiilor directe între modalităţi, dar fiind sensibilă la diferenţele de eşantionare şi aliniere temporală. Late Fusion (Decision-Level Fusion) procesează fiecare modalitate independent, combinând ulterior probabilităţile de ieşire printr-o regulă de agregare — abordare care oferă modularitate ridicată şi este bine adaptată sistemului propus, unde componenta vizuală şi cea auditivă sunt procesate de arhitecturi eterogene. Model-Level Fusion integrează reprezentările modalităţilor prin meta-clasificatori, captând interacţiuni complexe inter-modale cu preţul unei complexităţi computaţionale mai ridicate.

3.5.1. Late Fusion cu ponderi fixe

Late Fusion (Decision-Level Fusion) procesează fiecare ramură — vizuală şi auditivă — independent, fiecare generând propriul vector de probabilităţi prin aplicarea funcţiei Softmax pe cele şase clase emoţionale. Modularitatea ridicată a acestei abordări — modelele unimodale pot fi antrenate, optimizate şi înlocuite independent, fără a afecta restul sistemului — o recomandă ca strategie adecvată pentru sisteme multimodale cu arhitecturi eterogene [15]. Arhitectura Late Fusion este ilustrată în Figura 3.

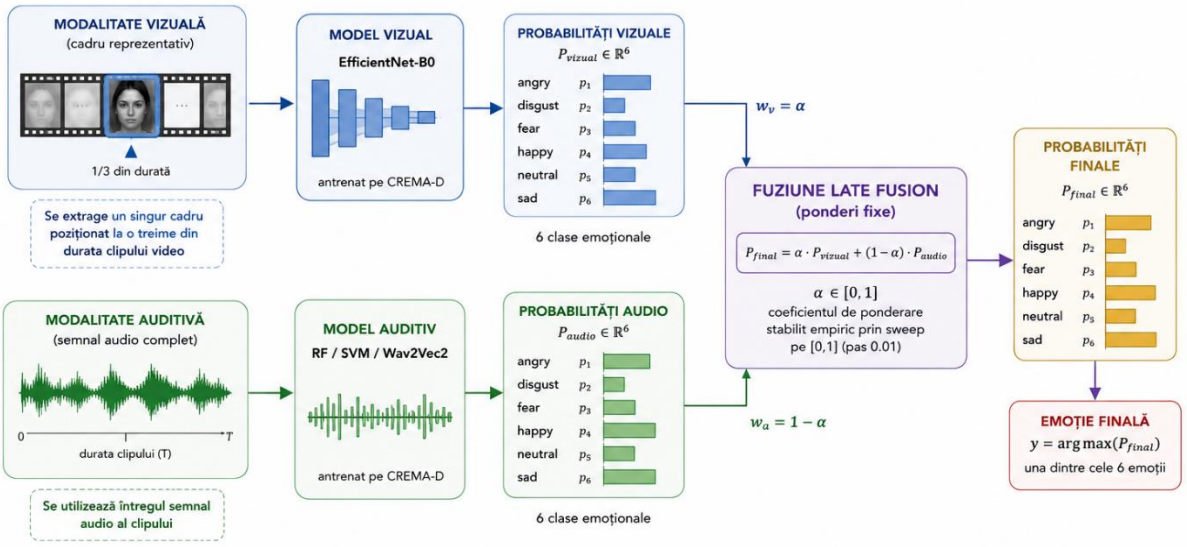


Figura 3. Arhitectura Late Fusion

sursă proprie

Fiecare ramură procesează datele separat şi generează propriul vector de probabilităţi — $P_{vizual} \in \mathbb{R}^6$, respectiv $P_{audio} \in \mathbb{R}^6$. Combinarea celor doi vectori se poate realiza prin mai multe strategii: media neponderată calculează vectorul fuzionat ca medie aritmetică, tratând ambele modalităţi ca egale; media ponderată permite ajustarea contribuţiei fiecărei modalităţi printr-un coeficient α; votul majoritar aplică funcţia arg max pe vectorii individuali şi combină deciziile finale.

În cadrul lucrării a fost implementată varianta cu medie ponderată, prin agregare liniară:

$$P_{final} = \alpha \cdot P_{vizual} + (1 - \alpha) \cdot P_{audio},$$

sau, echivalent,

$$P_{final} = w_{vizual} \cdot P_{vizual} + w_{audio} \cdot P_{audio},$$

unde $w_{vizual} + w_{audio} = 1$ şi $\alpha \in [0, 1]$ controlează contribuţia relativă a fiecărei modalităţi. Predicţia finală multimodală este obţinută prin aplicarea funcţiei argmax pe vectorul fuzionat P_{final}, selectând clasa emoţională cu probabilitatea maximă,

$$\text{emoție} = \text{argmax}(P_{final}).$$

Ponderile nu sunt fixate a priori, ci determinate empiric prin sweep exhaustiv pe intervalul [0, 1] cu pasul 0.01, evaluând toate combinaţiile vizual–audio pe setul de testare CREMA-D. Această procedură identifică ponderea optimă per combinaţie, reflectând contribuţia relativă a fiecărei modalităţi în funcţie de calitatea reprezentărilor generate. Principalele avantaje constau în robusteţe şi simplitate, limitând propagarea erorilor dintr-o ramură către predicţia finală.

3.5.2. Late Fusion adaptivă bazată pe entropia Shannon

Pentru creşterea robusteţii deciziei multimodale în condiţii reale de zgomot şi degradare senzorială, metodologia propusă introduce o strategie adaptivă de Late Fusion, bazată pe estimarea incertitudinii fiecărei componente unimodale. Spre deosebire de abordarea cu ponderi fixe, metoda ajustează dinamic contribuţia fiecărei modalităţi în funcţie de nivelul de încredere al predicţiilor generate, fără a necesita reantrenarea modelelor sau introducerea unor parametri suplimentari complecşi.

Fiecare componentă a sistemului — vizuală şi auditivă — produce independent un vector de probabilităţi, $P_{vizual} \in \mathbb{R}^6$ respectiv $P_{audio} \in \mathbb{R}^6$, obţinut prin aplicarea funcţiei Softmax. Gradul de incertitudine asociat fiecărei predicţii este cuantificat utilizând entropia Shannon [12], definită ca:

$$H(P) = -\sum_{i=1}^{n} p_i \cdot \log p_i$$

unde p_i reprezintă probabilitatea asociată clasei i din spaţiul discret de şase clase emoţionale. Entropia constituie o măsură directă a dispersiei distribuţiei de probabilitate: valori scăzute indică o predicţie concentrată şi un nivel ridicat de încredere, în timp ce valori ridicate semnalează ambiguitate sau degradarea semnalului de intrare.

Pe baza entropiei calculate, ponderile asociate fiecărei modalităţi sunt ajustate exponenţial:

$$w_{vizual} = e^{-\beta \cdot H(Pvizual)}$$

$$w_{audio} = e^{-\beta \cdot H(Paudio)}$$

Vectorul de fuziune este calculat prin normalizarea ponderilor:

$$P_{final} = (w_{vizual} \cdot P_{vizual} + w_{audio} \cdot P_{audio}) / (w_{vizual} + w_{audio})$$

unde parametrul $\beta \in [0, 1]$ controlează sensibilitatea mecanismului de adaptare — valori mari ale lui β amplifică diferenţele de încredere între modalităţi, în timp ce $\beta = 0$ reduce strategia la o medie neponderată. Valoarea optimă a lui β este determinată prin sweep pe intervalul [0, 1] cu pasul 0.05, evaluând toate combinaţiile vizual–audio pe setul de testare CREMA-D.

Fluxul complet al strategiei de Late Fusion adaptivă, de la predicţiile unimodale până la decizia emoţională finală, este ilustrat în Figura 4.

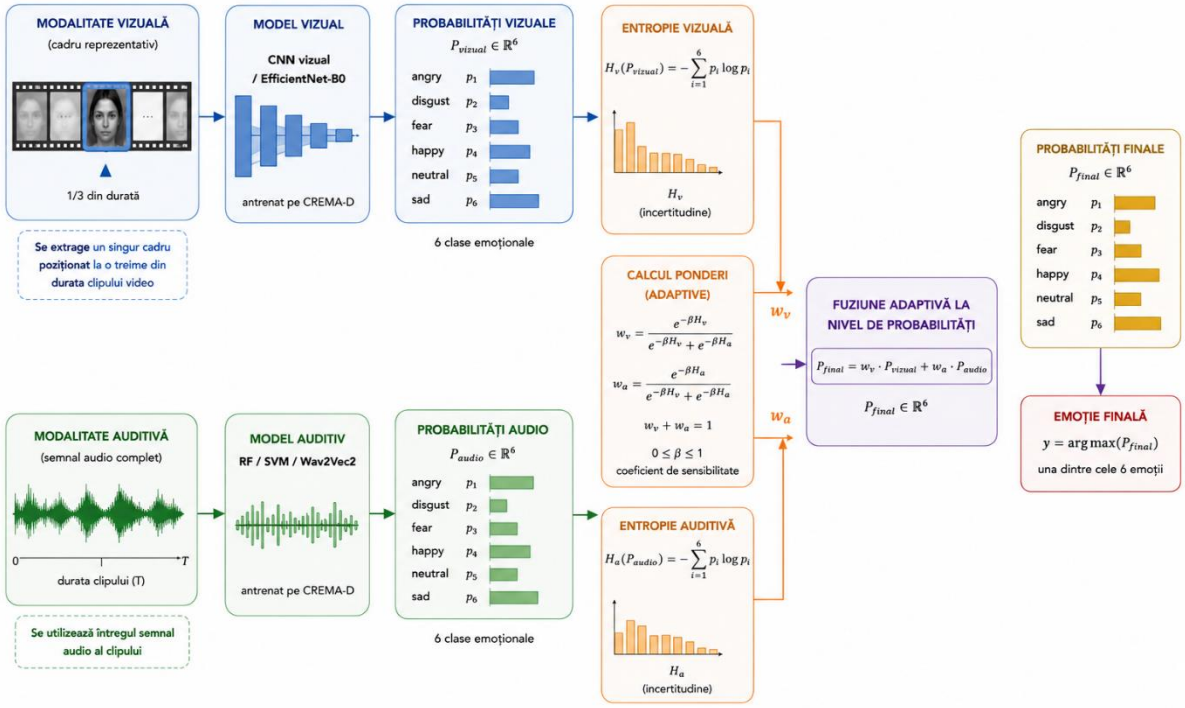


Figura 4. Strategie adaptivă Late Fusion bazată pe estimarea entropiei
sursă proprie

În practică, atunci când componenta vizuală prezintă o entropie ridicată — de exemplu, în situaţii de blur, ocluzii sau iluminare nefavorabilă — contribuţia acesteia este redusă automat, iar sistemul favorizează informaţia furnizată de componenta auditivă. În mod complementar, în prezenţa zgomotului ambiental sau a degradării semnalului vocal, ponderea componentei auditive este diminuată, iar decizia finală se bazează predominant pe informaţia vizuală. Cele două scenarii complementare sunt ilustrate în Figura 5.

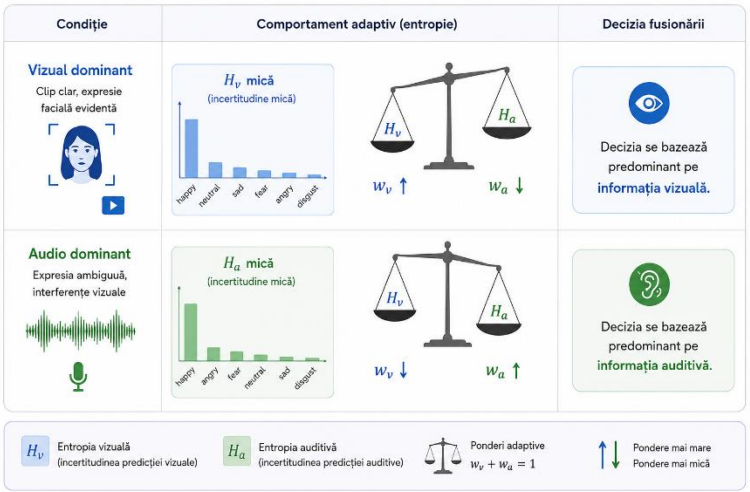


Figura 5. Comportament adaptiv al fuziunii bazate pe entropie - scenarii ilustrative
sursă proprie

Această strategie păstrează avantajele fundamentale ale Late Fusion — modularitate și independența antrenării modelelor unimodale — și le extinde printr-un mecanism adaptiv de ponderare, adecvat rulării în timp real pe dispozitive cu resurse limitate.

3.5.3. Model-Level Fusion

Model-Level Fusion reprezintă o strategie de fuziune multimodală în care decizia finală nu este obţinută printr-o regulă de agregare fixă, ci printr-un mecanism de decizie învăţat. Spre deosebire de Late Fusion cu ponderi fixe sau adaptivă, meta-clasificatorul antrenat pe vectorii de probabilitate concatenaţi are capacitatea de a captura interdependenţe non-liniare între modalităţi, exploatând relaţiile complexe dintre distribuţiile de probabilitate vizuală şi auditivă [15].

În cadrul lucrării, vectorii de probabilitate $P_{vizual} \in \mathbb{R}^6$ şi $P_{audio} \in \mathbb{R}^6$, produşi independent de fiecare ramură unimodală, sunt concatenaţi într-un vector de fuziune:

$v_{fusion} = [P_{vizual} ; P_{audio}] \in \mathbb{R}^{12}$

Acest vector constituie intrarea unui meta-clasificator antrenat pe setul de antrenare CREMA-D, care învaţă să combine şi să pondereze non-liniar informaţiile din cele două modalităţi, producând o decizie multimodală superioară agregării liniare simple.

Arhitectura corespunzătoare este ilustrată în Figura 6.

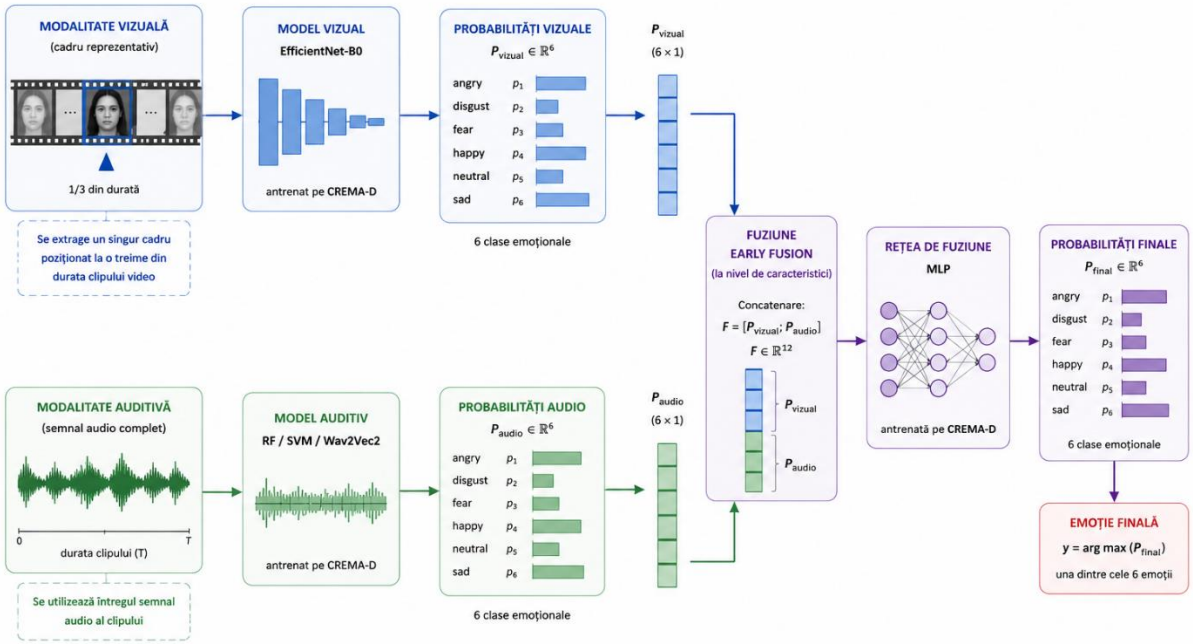


Figura 6. Fuziune Model-Level Fusion prin meta-clasificator

sursă proprie

Au fost evaluate două variante de meta-clasificatori: Logistic Regression şi Random Forest, selectaţi pentru robusteţea lor pe spaţii de intrare de dimensiune redusă. Logistic Regression modelează decizia finală printr-o funcţie liniară aplicată vectorului concatenat, cu regularizare L2 şi optimizare prin solver lbfgs. Random Forest construieşte un ansamblu de arbori de decizie pe acelaşi vector de fuziune $\mathbb{R}^{12}$, exploatând relaţiile non-liniare dintre componentele vizuale şi auditive ale distribuţiilor de probabilitate.

Clasificatorul MLP a fost evaluat în cadrul experimentelor preliminare, însă a prezentat overfitting sistematic în toate configuraţiile testate, cu diferenţe de 20–50% între acurateţea pe setul de antrenare şi cea pe setul de testare. Această comportare este

cauzată de dimensionalitatea redusă a spațiului de intrare — 12 caracteristici reprezentând vectorii de probabilitate concatenați — insuficientă pentru a justifica capacitatea unui perceptron multistrat, indiferent de parametrii de regularizare utilizați. În consecință, MLP a fost exclus din analiza comparativă finală, Logistic Regression și Random Forest dovedind a fi alegeri mai robuste pentru fuziunea la nivel de model pe vectori de probabilitate de dimensiune mică.

3.5.4. Early Fusion — motivarea excluderii

Early Fusion (Feature-Level Fusion) presupune concatenarea vectorilor de caracteristici extrași din straturile de reprezentare ale modelelor, anterior clasificării finale [15]. În această configurație, vectorii de trăsături rezultați din straturile convoluționale ale modelului vizual — după operațiunea Global Average Pooling — f_vizual, sunt concatenați cu vectorii de caracteristici audio extrași prin coeficienți MFCC, f_audio, obținând un vector combinat:

$v_{fusion} = [f_{vizual} ; f_{audio}]$

care este ulterior procesat de un set de straturi fully-connected pentru obținerea predicției finale. Arhitectura corespunzătoare este ilustrată în Figura 7.

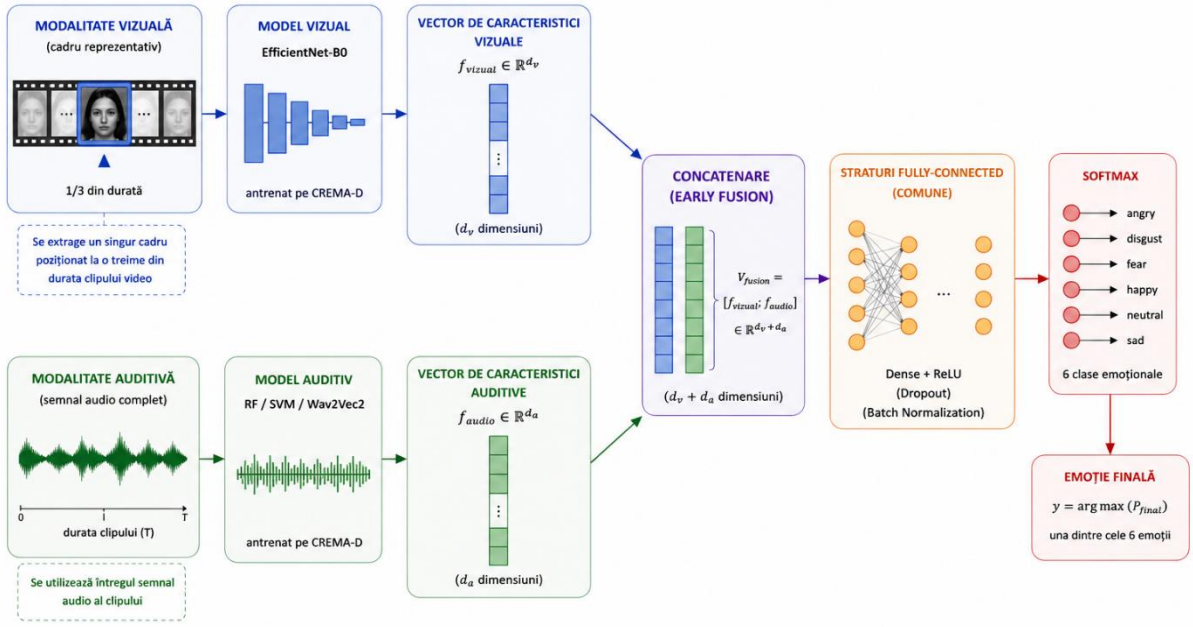


Figura 7. Arhitectura Early Fusion

sursă proprie

Principalul avantaj al acestei strategii constă în posibilitatea de a captura corelații directe și interacțiuni de nivel scăzut între cele două modalități încă din faza incipientă a procesării. Cu toate acestea, Early Fusion prezintă limitări importante în contextul sistemului propus.

În primul rând, strategia necesită o aliniere temporală strictă între fluxurile vizual și auditiv, fiind sensibilă la diferențele de frecvență de eșantionare și la absența sau degradarea unuia dintre senzori. În al doilea rând, incompatibilitatea dimensională dintre vectorii vizuali — proveniți din straturi convoluționale de dimensiuni variabile în funcție de rezoluția imaginii — și vectorii MFCC 300D face concatenarea directă dificil de

justificat din punct de vedere semantic. În al treilea rând, antrenarea end-to-end a unui sistem Early Fusion pe CREMA-D, care conține doar 5.967 mostre de antrenare, prezintă un risc ridicat de overfitting datorită dimensionalității mari a spațiului de intrare rezultat din concatenare.

Din aceste motive, Early Fusion a fost exclusă din implementarea experimentală, fiind menținută în lucrare exclusiv ca referință conceptuală în analiza comparativă a strategiilor de fuziune multimodală.

3.6. Strategia de evaluare cross-dataset

Evaluarea capacității de generalizare a unui sistem multimodal de recunoaștere a emoțiilor reprezintă o provocare metodologică distinctă față de evaluarea clasică pe seturi de date separate train/test. Un sistem care obține performanțe ridicate pe setul de testare din aceeași distribuție cu datele de antrenare nu garantează în mod necesar robustețe în condiții reale, unde actorii, condițiile de înregistrare și caracteristicile acustice diferă semnificativ față de cele văzute în antrenare [7].

În contextul acestei lucrări, evaluarea cross-dataset implică testarea modelelor antrenate exclusiv pe CREMA-D pe date provenite din RAVDESS — un set de date diferit, cu actori distincți, condiții de studio diferite și caracteristici prosodice proprii. Această abordare permite cuantificarea directă a capacității de generalizare a sistemului multimodal dincolo de distribuția datelor de antrenare.

Strategia de evaluare cross-dataset adoptată urmează un protocol riguros în trei etape. În prima etapă, toate modelele unimodale — CNN, EfficientNet-B0, Random Forest, SVM și Wav2Vec2 — sunt antrenate exclusiv pe setul CREMA-D, fără nicio expunere la datele RAVDESS în faza de antrenare. În a doua etapă, vectorii de probabilitate $P_{vizual} \in \mathbb{R}^6$ și $P_{audio} \in \mathbb{R}^6$ sunt generați prin inferența modelelor antrenate pe imaginile și semnalele audio extrase din RAVDESS, preprocesate identic cu datele de antrenare CREMA-D — același interval de extracție a cadrului vizual, aceeași structură a vectorului MFCC 300D și aceleași rezoluții de imagine. În a treia etapă, strategia de fuziune câștigătoare identificată pe CREMA-D pentru fiecare combinație vizual–audio este aplicată direct pe vectorii RAVDESS, fără reoptimizarea parametrilor de fuziune pe datele externe.

Pentru strategiile Late Fusion — atât cu ponderi fixe cât și adaptivă bazată pe entropia Shannon — parametrii optimizați pe CREMA-D (α_optim și β_optim) sunt aplicați direct pe datele RAVDESS, testând astfel robustețea parametrilor de fuziune în condiții cross-dataset. Pentru Model-Level Fusion, meta-clasificatorii Logistic Regression și Random Forest sunt reantrenați pe vectorii de probabilitate CREMA-D și aplicați pe vectorii corespondenți generați pe RAVDESS, menținând separarea strictă între datele de antrenare și cele de evaluare externă.

Această metodologie asigură că rezultatele obținute pe RAVDESS reflectă capacitatea reală de generalizare a sistemului multimodal, eliminând orice formă de data leakage între seturile de date. Evaluarea acoperă toate combinațiile vizual–audio, iar pentru fiecare combinație este raportată atât acuratețea obținută pe CREMA-D, cât și cea obținută pe RAVDESS, permițând o analiză directă a degradării performanței în scenariul cross-dataset și identificarea configurațiilor cu cea mai bună capacitate de generalizare.

CAPITOLUL 4 – REZULTATE EXPERIMENTALE

Prezentul capitol prezintă rezultatele experimentale obţinute în urma antrenării modelelor unimodale şi a evaluării strategiilor de fuziune multimodală propuse în Capitolul 3. Experimentele sunt structurate în două etape principale: evaluarea individuală a modelelor unimodale vizuale şi auditive pe setul de testare CREMA-D, urmată de evaluarea comparativă a strategiilor de fuziune multimodală şi validarea cross-dataset pe setul RAVDESS.

4.1. Configuraţia experimentală

În cadrul acestei lucrări au fost antrenate opt configuraţii de modele vizuale şi trei modele auditive, toate pe setul de date CREMA-D, conform metodologiei descrise în Capitolul 3. Partiţionarea datelor a fost realizată la nivel de actor pentru prevenirea data leakage — actorii 1001–1073 constituind setul de antrenare (5.967 mostre), iar actorii 1074–1091 setul de testare (1.475 mostre).

Modelele vizuale antrenate acoperă două arhitecturi evaluate la rezoluţiile 64×64 şi 128×128 pixeli, în format color şi grayscale, generând opt configuraţii distincte: CNN_64_color, CNN_64_gray, CNN_128_color, CNN_128_gray, EfficientNetB0_64_color, EfficientNetB0_64_gray, EfficientNetB0_128_color şi EfficientNetB0_128_gray. Modelele auditive antrenate sunt: Random Forest pe vectori MFCC 300D, SVM cu kernel RBF pe aceiaşi vectori şi Wav2Vec2 fine-tuned pe semnal audio brut.

Combinarea celor opt configuraţii vizuale cu cele trei modele auditive generează 24 de combinaţii vizual–audio, evaluate exhaustiv pentru toate cele trei strategii de fuziune implementate: Late Fusion cu ponderi fixe, Late Fusion adaptivă bazată pe entropia Shannon şi Model-Level Fusion cu meta-clasificatori Logistic Regression şi Random Forest.

Metricile principale utilizate sunt acurateţea Top-1 şi scorul F1 macro — media scorurilor F1 individuale pe cele şase clase emoţionale. Sincronizarea temporală dintre fluxurile vizual şi auditiv se realizează prin extracţia unui cadru reprezentativ poziţionat la o treime din durata totală a clipului video, combinat cu vectorul de caracteristici audio MFCC 300D extras din acelaşi clip, conform metodologiei descrise în subcapitolul 3.4.

Toate experimentele au fost realizate pe o staţie de lucru cu procesor Intel Core i7-13700H şi 16 GB RAM, fără accelerare GPU, cu excepţia fine-tuning-ului modelului Wav2Vec2, care a fost realizat în Google Colab cu accelerare GPU T4.

4.2. Rezultate modele unimodale

Modelele vizuale şi auditive sunt evaluate pe setul de testare CREMA-D (1.475 mostre), utilizând metricile Top-1, Top-2 şi F1 macro. Rezultatele sunt prezentate individual, însoţite de graficele de evoluţie a antrenării şi matricele de confuzie.

4.2.1. Modele vizuale pe CREMA-D

Arhitectura CNN

Reţeaua CNN propusă urmează o structură secvenţială cu patru blocuri convoluţionale şi un cap de clasificare, fiind identică pentru toate cele opt configuraţii —

variind exclusiv dimensiunea tensorului de intrare: (64×64×1) şi (128×128×1) pentru configuraţiile grayscale, respectiv (64×64×3) şi (128×128×3) pentru cele color.

Fiecare bloc convoluţional conţine două straturi Conv2D cu nuclee de 3×3 şi activare ReLU, urmate de BatchNormalization, MaxPooling2D de 2×2 şi Dropout pentru regularizare. Numărul de filtre creşte progresiv de la 32 în primul bloc la 64, 128 şi 256 în blocurile următoare, asigurând extracţia de caracteristici la niveluri crescânde de abstractizare, iar rata Dropout creşte corespunzător de la 0.25 la 0.40 pentru a contrabalansa capacitatea sporită a modelului. După ultimul bloc convoluţional, un strat GlobalAveragePooling2D înlocuieşte aplatizarea clasică, reducând dimensionalitatea şi limitând supraadaptarea. Capul de clasificare constă din două straturi Dense de 512, respectiv 256 neuroni cu activare ReLU şi iniţializare He Normal, fiecare urmat de Dropout 0.5, şi un strat de ieşire cu 6 neuroni şi activare softmax. Modelul totalizează 1.439.974 parametri antrenabili.

Augmentarea datelor este integrată direct în arhitectură prin straturi RandomFlip, RandomContrast şi RandomRotation, active exclusiv în faza de antrenare. Optimizatorul utilizat este Adam cu rată de învăţare iniţială de 5×10^{-4}, funcţia de pierdere este categorical crossentropy, iar antrenarea este controlată prin EarlyStopping (patience=20), ReduceLROnPlateau (factor=0.5, patience=10) şi ModelCheckpoint, cu maximum 200 epoci şi batch size 32.

Cele opt configuraţii vizuale au fost antrenate şi evaluate pe setul CREMA-D (1.475 mostre test, 6 clase emoţionale), utilizând metricile Top-1, Top-2 şi F1 macro. Rezultatele comparative sunt prezentate în Tabelul 1.

Tabelul 1. Rezultate comparative — modele vizuale pe CREMA-D

Configuraţie	Top-1 (%)	Top-2 (%)	F1 macro
CNN_64_color	57.63	77.42	0.57
CNN_64_gray	58.85	76.81	0.57
CNN_128_color	56.75	79.12	0.56
CNN_128_gray	57.42	79.05	0.57
EfficientNetB0_64_color	43.53	63.59	0.40
EfficientNetB0_64_gray	46.10	65.76	0.44
EfficientNetB0_128_color	50.37	71.53	0.47
EfficientNetB0_128_gray	48.81	71.53	0.46

Cele patru configuraţii CNN obţin rezultate omogene, cu Top-1 cuprins între 56.75% şi 58.85% şi F1 macro între 0.56 şi 0.57. Variaţia redusă de 2.1 puncte procentuale confirmă robusteţea arhitecturii faţă de schimbările de rezoluţie şi format de culoare. Configuraţia CNN_64_gray obţine cel mai bun Top-1 (58.85%), sugerând că eliminarea informaţiei cromatice — irelevantă în contextul înregistrărilor CREMA-D realizate în studio cu fundal uniform — reduce zgomotul şi facilitează concentrarea modelului pe trăsăturile geometrice ale expresiei faciale. Configuraţiile la 128×128 obţin Top-2

superioare (79.12% și 79.05%), indicând că rezoluția mai mare îmbunătățește discriminarea în primele două clase cele mai probabile.

Analiza per clasă relevă un pattern consistent: clasa happy obține cel mai ridicat F1 (0.79–0.85), beneficiind de expresii faciale distinctive, în timp ce clasa sad prezintă cel mai scăzut F1 (0.35–0.40), reflectând suprapunerea expresivă cu neutral și fear. Clasa disgust obține scoruri bune (F1 0.70–0.75) datorită caracteristicilor faciale distinctive. Rapoartele detaliate per clasă pentru configurațiile CNN sunt prezentate în Tabelul 2.

Tabelul 2. F1 per clasă — configurații CNN pe CREMA-D

Clasă	CNN_64_color	CNN_64_gray	CNN_128_color	CNN_128_gray
angry	0.47	0.5	0.41	0.45
disgust	0.72	0.75	0.72	0.7
fear	0.53	0.52	0.51	0.5
happy	0.79	0.79	0.8	0.85
neutral	0.53	0.5	0.53	0.54
sad	0.36	0.4	0.4	0.35

Graficele de antrenare și matricele de confuzie pentru configurațiile CNN sunt prezentate în Figura 8 (64×64) și Figura 9 (128×128), gray și color.

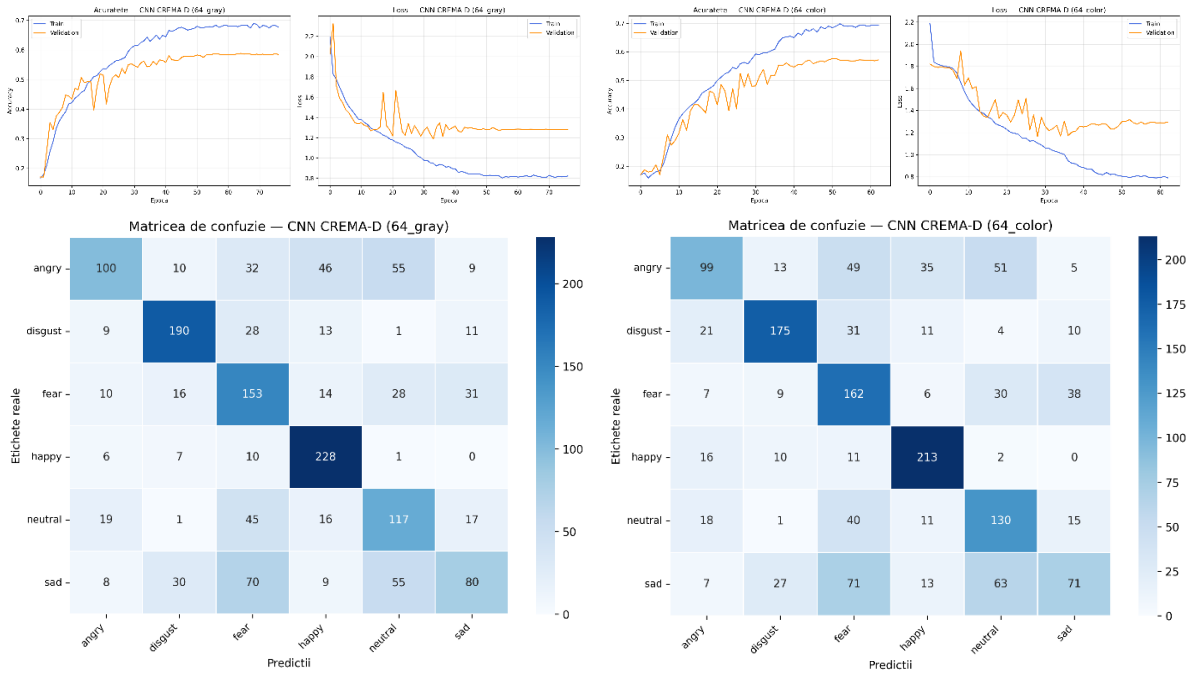


Figura 8. Grafice de antrenare și matrice de confuzie — CNN 64×64
sursă proprie

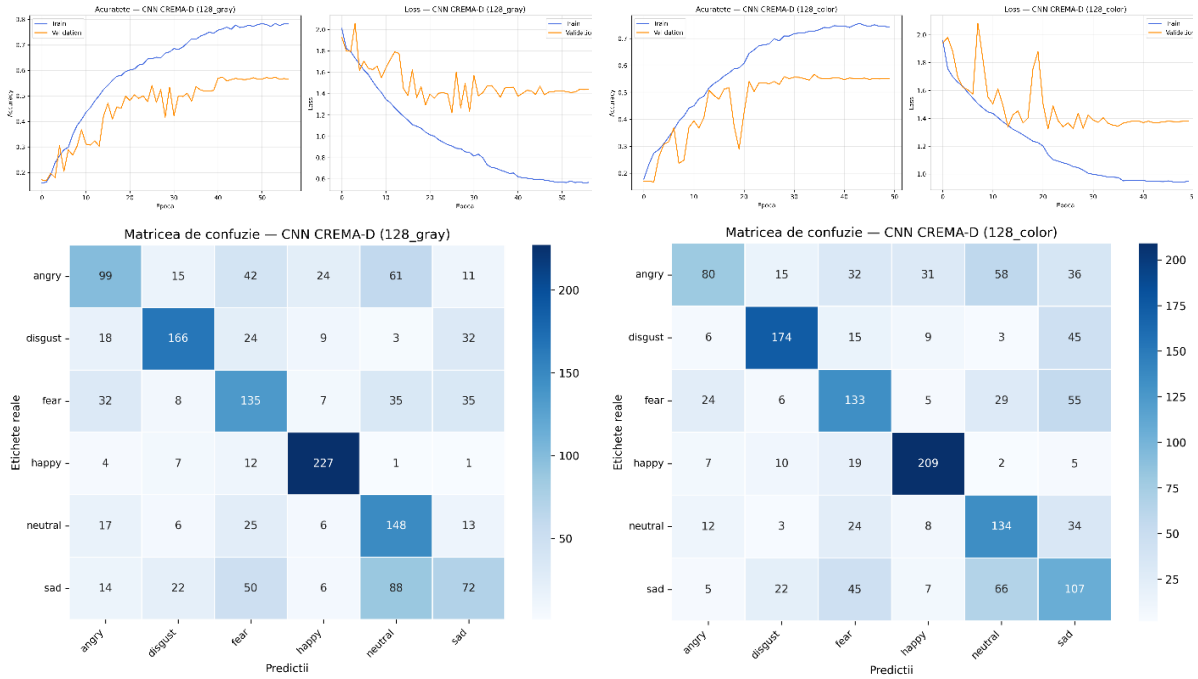


Figura 9. Grafice de antrenare şi matrice de confuzie — CNN 128×128
sursă proprie

Arhitectura EfficientNet-B0

Modelele EfficientNetB0 valorifică transferul de cunoştinţe de la reţeaua pre-antrenată pe ImageNet, cu capul original de clasificare complet înlocuit. Baza EfficientNetB0 — fără stratul top — este conectată la un strat GlobalAveragePooling2D, urmat de un cap extins format din două straturi Dense de 512, respectiv 256 neuroni cu activare ReLU şi iniţializare He Normal, cu BatchNormalization şi Dropout 0.4 după primul strat, Dropout 0.3 după al doilea, şi un strat de ieşire cu 6 neuroni şi activare softmax. Modelul totalizează 4.840.361 parametri în total, din care 789.766 sunt antrenabili în prima fază.

Antrenarea se desfăşoară în două faze distincte. În Faza 1 — extracţie de caracteristici — baza EfficientNetB0 este complet îngheţată şi se antrenează exclusiv capul, cu rată de învăţare 3×10^{-4} şi maximum 100 epoci. În Faza 2 — fine-tuning — blocurile block4 până la block7 ale bazei sunt deblocate şi antrenate împreună cu capul, cu rată de învăţare redusă la 1×10^{-5} şi maximum 150 epoci suplimentare. Augmentarea datelor, activă în ambele faze, include RandomFlip, RandomRotation (±15°), RandomTranslation (±10%), RandomZoom (±15%) şi RandomContrast (±30%). Callback-urile şi strategia de gestionare a dezechilibrului de clase prin ponderi compute_class_weight sunt identice cu cele descrise pentru CNN.

Un aspect particular al configuraţiilor grayscale EfficientNetB0 îl reprezintă cerinţa arhitecturii de a primi obligatoriu un tensor cu 3 canale la intrare, impusă de pre-antrenarea pe ImageNet. Prin urmare, imaginile grayscale sunt convertite în format pseudo-RGB prin replicarea canalului unic pe toate cele trei canale de intrare, obţinând tensori de shape (64×64×3) şi (128×128×3). Această abordare păstrează compatibilitatea cu baza pre-antrenată fără a modifica arhitectura, permiţând modelului

să valorifice reprezentările învățate pe ImageNet chiar și în absența informației cromatice.

Cele patru configurații EfficientNet-B0 fine-tuned obțin rezultate inferioare față de CNN, cu Top-1 cuprins între 43.53% și 50.37% și F1 macro între 0.40 și 0.47. Configurația EfficientNetB0_128_color obține cel mai bun rezultat (50.37% Top-1, 71.53% Top-2, F1 macro 0.47). Spre deosebire de CNN, rezoluția 128×128 depășește consistent 64×64, sugerând că EfficientNet — pre-antrenat pe ImageNet în format RGB — necesită rezoluții mai mari pentru a valorifica reprezentările pre-antrenate. Analiza per clasă relevă dificultăți sistematice pentru clasele fear și sad, cu F1 de 0.23–0.36 respectiv 0.17–0.28 — semnificativ mai scăzute față de CNN — în timp ce clasa happy rămâne cea mai bine clasificată (F1 0.60–0.66). Rapoartele detaliate per clasă sunt prezentate în Tabelul 3.

Tabelul 3. F1 per clasă — configurații EfficientNet-B0 pe CREMA-D

Clasă	Eff_64_color	Eff_64_gray	Eff_128_color	Eff_128_gray
angry	0.38	0.38	0.41	0.46
disgust	0.65	0.63	0.65	0.64
fear	0.23	0.35	0.33	0.36
happy	0.60	0.62	0.66	0.65
neutral	0.37	0.40	0.51	0.40
sad	0.17	0.25	0.26	0.28

Performanța inferioară față de CNN se explică prin incompatibilitatea dintre rezoluțiile utilizate (64×64 și 128×128) și rezoluția nativă de 224×224 pentru care EfficientNet-B0 a fost proiectat, limitând capacitatea de transfer a reprezentărilor pre-antrenate pe ImageNet.

Graficele de antrenare și matricele de confuzie pentru configurațiile EfficientNet-B0 sunt prezentate în Figura 10. (64×64) și Figura 11. (128×128), gray și color.

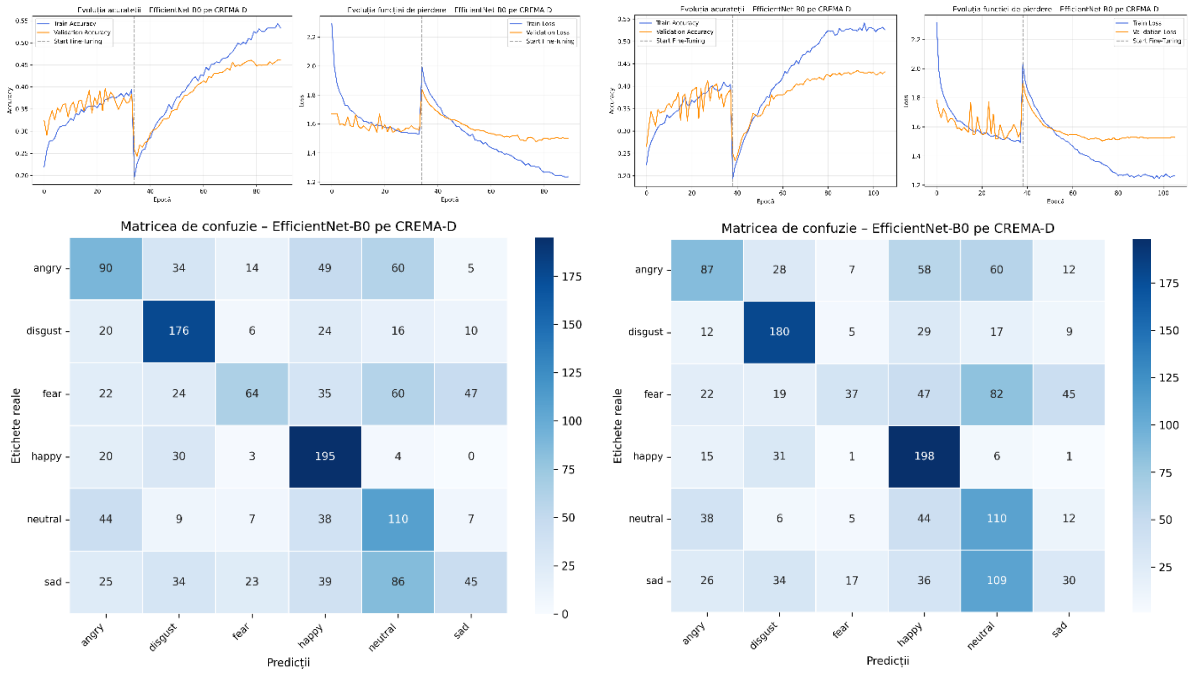


Figura 10. Grafice de antrenare şi matrice de confuzie — EfficientNet-B0 64×64
sursă proprie

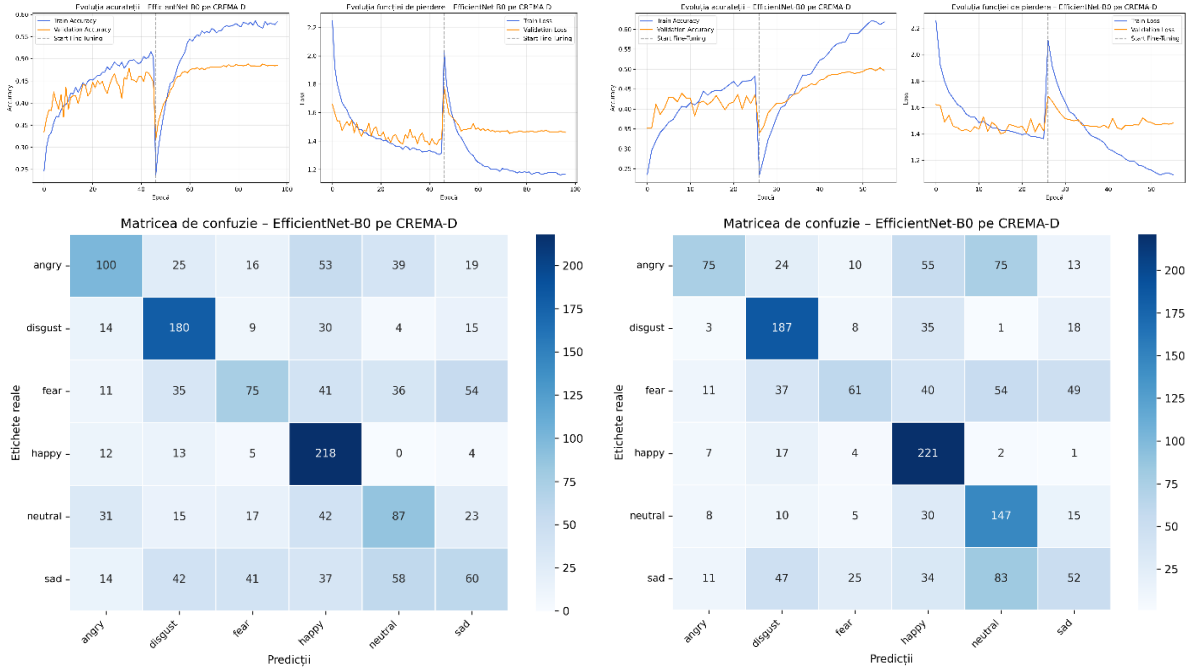


Figura 11. Grafice de antrenare şi matrice de confuzie - EfficientNet-B0 128×128
sursă proprie

4.2.2. Modele audio pe CREMA-D

Random Forest şi SVM pe vectori MFCC 300D

Modelele Random Forest şi SVM au fost antrenate pe reprezentări audio de tip vector de caracteristici, construite prin extracţie manuală cu librosa. Pentru fiecare înregistrare, vectorul de 300 de dimensiuni înglobează patru tipuri de informaţie

spectrală: media, deviaţia standard şi maximul coeficienţilor MFCC — contribuind cu 120 de dimensiuni — media coeficienţilor delta MFCC de ordinul întâi (40 dimensiuni), media caracteristicilor chroma (12 dimensiuni) şi media spectrogramei mel în scală logaritmică (128 dimensiuni).

Modelul Random Forest a fost antrenat cu 2.000 de arbori de decizie, folosind criteriul entropiei pentru selecţia împărţirilor şi rădăcina pătrată din numărul total de caracteristici per nod. Dezechilibrul dintre clase este corectat prin ponderi de clasă echilibrate, calculate automat în funcţie de distribuţia setului de antrenare.

Modelul SVM foloseşte un kernel RBF cu C=10 şi gamma adaptat la scara datelor, cu activarea estimării probabilistice — necesară pentru generarea vectorilor de probabilitate utilizaţi în fuziunea multimodală. Întrucât SVM este sensibil la scara caracteristicilor, vectorii de intrare au fost normalizaţi prin StandardScaler înainte de antrenare, scalatorul fiind salvat separat pentru a garanta o preprocesare identică la inferenţă.

Wav2Vec2 fine-tuned

Modelul audio de referinţă porneşte de la arhitectura wav2vec2-base-superb-er — o variantă Wav2Vec2-Base pre-antrenată pe 960 de ore de vorbire englezească (LibriSpeech) şi ulterior fine-tuned pe recunoaşterea emoţiilor din vorbire. Spre deosebire de RF şi SVM, acest model operează direct pe semnalul audio brut la 16.000 Hz, fără extracţie manuală de caracteristici, şi totalizează aproximativ 94,4 milioane de parametri. Stratul de clasificare original a fost înlocuit cu unul nou cu 6 ieşiri corespunzătoare claselor CREMA-D.

Adaptarea modelului la setul CREMA-D a fost realizată în Google Colab cu accelerare GPU T4. Semnalele audio brute au fost tăiate sau completate cu zerouri la o lungime fixă de 4 secunde. Optimizatorul AdamW cu rată de învăţare 2×10^{-5} şi weight decay 0.01 a fost combinat cu un scheduler liniar cu perioadă de încălzire pe primele 10% din paşi, iar dezechilibrul de clase a fost tratat prin ponderi în funcţia de pierdere CrossEntropyLoss. Antrenarea s-a desfăşurat pe maximum 20 de epoci, cu Early Stopping cu patience 5 şi salvarea automată a checkpoint-ului la acurateţea maximă pe setul de test, cu un batch size de 8 impus de limitările de memorie ale mediului Colab.

Cele trei modele auditive au fost evaluate pe setul CREMA-D (1.475 mostre test, 6 clase), utilizând metricile Top-1, Top-2 şi F1 macro. Rezultatele comparative sunt prezentate în Tabelul 4.

Tabelul 4. Rezultate comparative — modele audio

Model	Top-1 (%)	Top-2 (%)	F1 macro
Random Forest (MFCC 300D)	44.81	68.88	0.43
SVM kernel RBF (MFCC 300D)	48.34	71.25	0.47
Wav2Vec2 fine-tuned	68.00	83.46	0.68

Wav2Vec2 fine-tuned depăşeşte SVM cu 19.66 puncte procentuale şi Random Forest cu 23.19 puncte procentuale la Top-1, confirmând superioritatea reprezentărilor

contextuale profunde față de trăsăturile MFCC clasice. Diferența se menține și la Top-2 — Wav2Vec2 obține 83.46% față de 71.25% pentru SVM și 68.88% pentru Random Forest.

Analiza per clasă pentru Wav2Vec2 relevă performanțe diferențiate: angry (F1 0.78) și happy (0.77) sunt cele mai bine clasificate, în timp ce fear prezintă cel mai scăzut F1 (0.49), cu recall de doar 0.38 — reflectând dificultatea acustică a acestei emoții, frecvent confundată cu sad și neutral. Random Forest și SVM prezintă dificultăți sistematice pe clasele disgust și fear, cu F1 de 0.28–0.43. Rapoartele detaliate per clasă sunt prezentate în Tabelul 5.

Tabelul 5. F1 per clasă — modele audio

Clasă	Random Forest	SVM	Wav2Vec2
angry	0.66	0.63	0.78
disgust	0.28	0.43	0.67
fear	0.29	0.33	0.49
happy	0.40	0.41	0.77
neutral	0.39	0.41	0.73
sad	0.54	0.58	0.62

Matricele de confuzie pentru Random Forest și SVM sunt prezentate în Figura 12. Graficul de antrenare și matricea de confuzie pentru modelul Wav2Vec2 fine-tuned sunt prezentate în Figura 13.

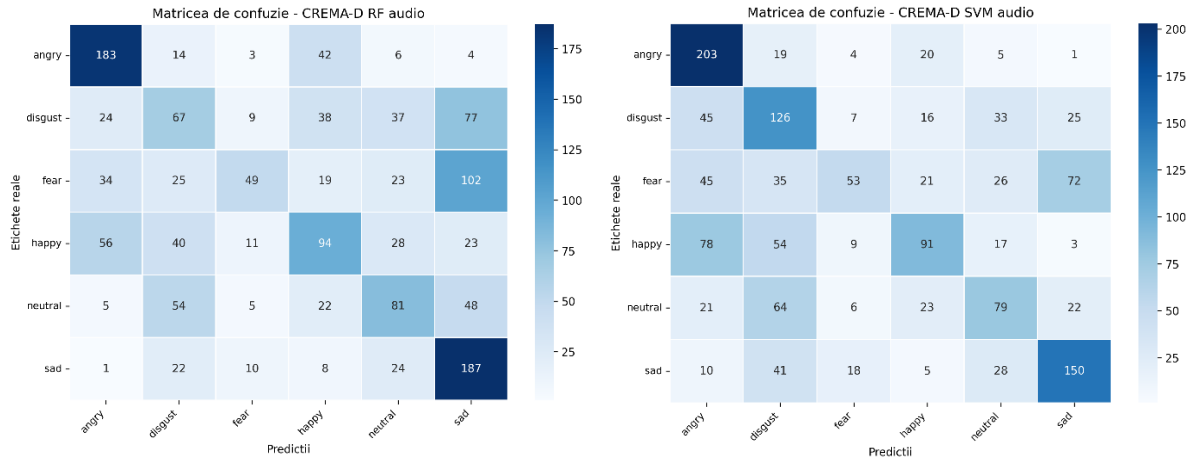


Figura 12. Matrice de confuzie — Random Forest și SVM
sursă proprie

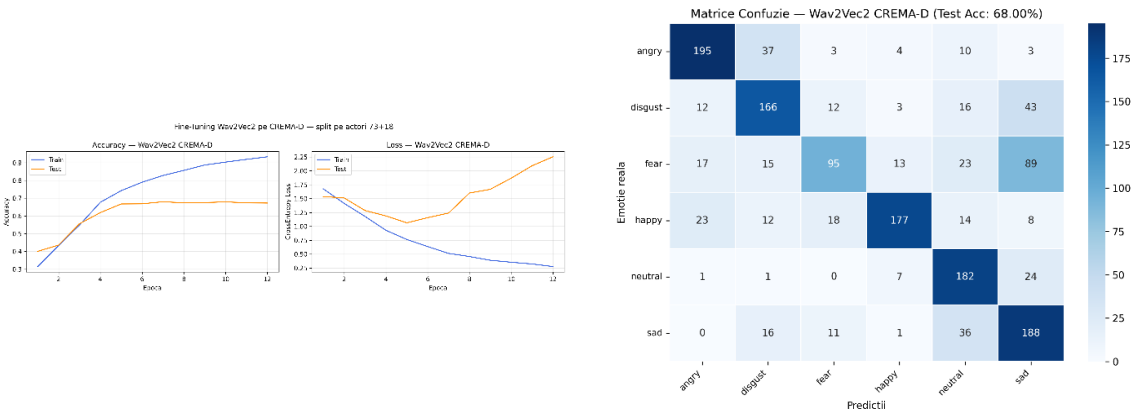


Figura 13. Grafic de antrenare şi matrice de confuzie — Wav2Vec2 fine-tuned
sursă proprie

4.2.3. Analiză comparativă — toate modelele unimodale

Tabelul 6 prezintă comparativ toate cele 11 configuraţii unimodale evaluate, oferind o imagine de ansamblu asupra performanţei componentelor vizuale şi auditive înainte de fuziune.

Tabelul 6. Tabel comparativ complet — toate modelele unimodale

Model	Modalitate	Top-1 (%)	Top-2 (%)	F1 macro
CNN_64_color	Vizual	57.63	77.42	0.57
CNN_64_gray	Vizual	58.85	76.81	0.57
CNN_128_color	Vizual	56.75	79.12	0.56
CNN_128_gray	Vizual	57.42	79.05	0.57
EfficientNetB0_64_color	Vizual	43.53	63.59	0.40
EfficientNetB0_64_gray	Vizual	46.10	65.76	0.44
EfficientNetB0_128_color	Vizual	50.37	71.53	0.47
EfficientNetB0_128_gray	Vizual	48.81	71.53	0.46
Random Forest	Audio	44.81	68.88	0.43
SVM	Audio	48.34	71.25	0.47
Wav2Vec2	Audio	68.00	83.46	0.68

Wav2Vec2 se detaşează clar ca cel mai performant model unimodal, depăşind cu 9.15 puncte procentuale cel mai bun model vizual (CNN_64_gray — 58.85%). Comparaţia F1 per clasă pentru modelele vizuale şi auditive este ilustrată în Figura 14. şi Figura 15.

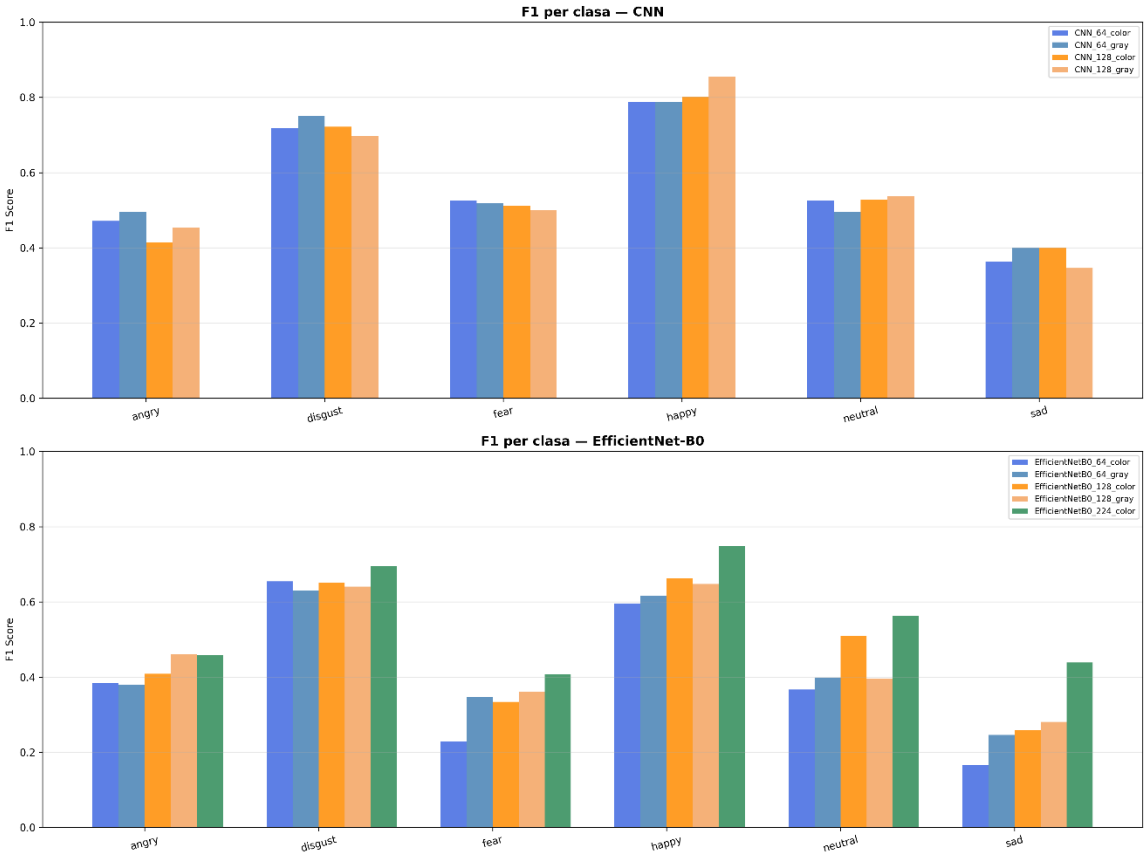


Figura 14. Comparație F1 per clasă —CNN și EfficientNet-B0
sursă proprie

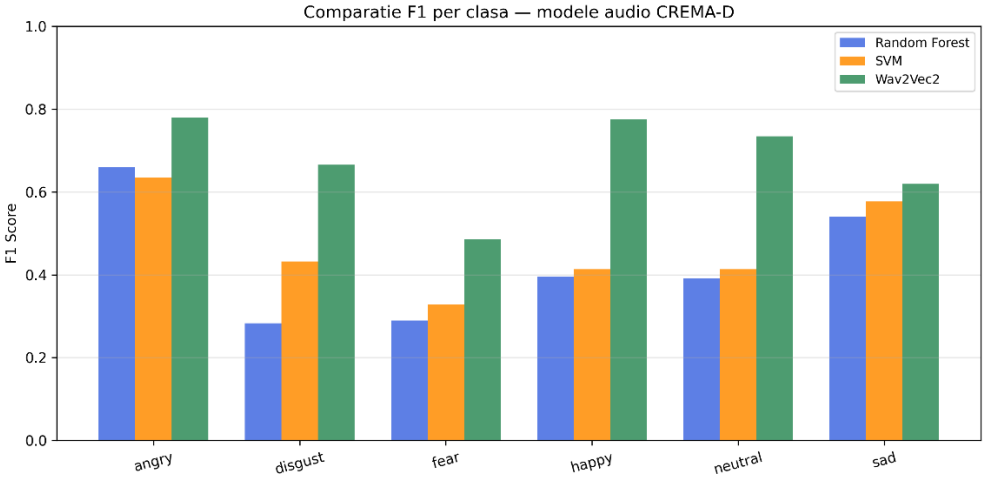


Figura 15. Comparație F1 per clasă — modele audio
sursă proprie

4.3. Rezultate fuziune multimodală pe CREMA-D

Cele trei strategii de fuziune multimodală — Late Fusion cu ponderi fixe, Late Fusion adaptivă bazată pe entropia Shannon și Model-Level Fusion — au fost evaluate exhaustiv pe toate cele 24 de combinații vizual–audio. Rezultatele complete, în ordine descrescătoare, sunt prezentate în procente, în Tabelul 7.

Tabelul 7. Rezultate comparative — toate strategiile de fuziune

Nr.	Combinatie	Vizual	Audio	LF(α)	LF(ent- β)	LR	RF	BEST	Fuziune
1	CNN_128_color + Wav2Vec2	56.70	68.00	73.80	73.20	75.60	77.60	77.56	RF
2	CNN_128_gray + Wav2Vec2	57.40	68.00	74.40	74.70	75.10	76.50	76.47	RF
3	CNN_64_color + Wav2Vec2	57.60	68.00	75.10	74.50	75.00	76.40	76.41	RF
4	CNN_64_gray + Wav2Vec2	58.80	68.00	75.70	75.50	74.60	76.30	76.34	RF
5	EfficientNetB0_128_color + Wav2Vec2	50.40	68.00	72.50	72.50	72.10	73.60	73.56	RF
6	EfficientNetB0_64_gray + Wav2Vec2	46.10	68.00	72.00	72.00	71.70	73.20	73.15	RF
7	EfficientNetB0_64_color + Wav2Vec2	43.50	68.00	71.50	71.40	72.20	72.90	72.88	RF
8	EfficientNetB0_128_gray + Wav2Vec2	48.80	68.00	71.80	71.60	70.90	72.40	72.41	RF
9	CNN_128_gray + SVM	57.40	48.30	67.90	66.10	60.70	58.10	67.93	LF(α)
10	CNN_64_color + SVM	57.60	48.30	67.90	67.90	60.30	55.90	67.93	LF(α)
11	CNN_64_gray + SVM	58.80	48.30	67.30	66.40	59.40	56.50	67.32	LF(α)
12	CNN_64_color + RF	57.60	44.80	66.60	64.60	61.70	43.90	66.58	LF(α)
13	CNN_128_gray + RF	57.40	44.80	66.20	62.40	61.50	45.30	66.24	LF(α)
14	CNN_64_gray + RF	58.80	44.80	66.00	64.40	61.80	43.50	66.03	LF(α)
15	CNN_128_color + RF	56.70	44.80	65.60	62.90	61.20	41.90	65.63	LF(α)
16	CNN_128_color + SVM	56.70	48.30	65.60	65.50	60.50	54.60	65.63	LF(α)
17	EfficientNetB0_128_color + RF	50.40	44.80	62.90	60.90	57.40	41.80	62.92	LF(α)
18	EfficientNetB0_128_color + SVM	50.40	48.30	61.80	61.60	56.70	53.00	61.76	LF(α)
19	EfficientNetB0_128_gray + RF	48.80	44.80	60.50	59.40	56.70	37.80	60.54	LF(α)
20	EfficientNetB0_128_gray + SVM	48.80	48.30	60.50	60.40	53.20	50.00	60.47	LF(α)
21	EfficientNetB0_64_color + RF	43.50	44.80	59.70	58.00	55.30	41.30	59.73	LF(α)
22	EfficientNetB0_64_gray + RF	46.10	44.80	59.40	58.50	55.10	41.30	59.39	LF(α)
23	EfficientNetB0_64_gray + SVM	46.10	48.30	58.70	58.60	54.20	49.60	58.71	LF(α)
24	EfficientNetB0_64_color + SVM	43.50	48.30	58.10	58.10	54.90	50.00	58.10	LF(α)

Analiza rezultatelor Late Fusion cu ponderi fixe

Late Fusion cu ponderi fixe aduce îmbunătăţiri consistente faţă de modelele unimodale în toate cele 24 de combinaţii. Câştigul mediu faţă de cel mai bun model unimodal al perechii este de 7–10 puncte procentuale pentru combinaţiile cu RF şi SVM audio, şi de 6–7 puncte pentru combinaţiile cu Wav2Vec2. Valorile optime ale parametrului α se situează în intervalul 0.29–0.58, cu o concentrare în jurul valorii 0.45–0.51, indicând o contribuţie aproape echilibrată a celor două modalităţi în majoritatea configuraţiilor. Excepţie face combinaţia CNN_128_gray + RF, unde α_optim = 0.30, reflectând dominanţa componentei vizuale faţă de RF audio, care obţine 44.81% — cel mai slab model audio.

Comportamentul parametrului α în Late Fusion

Graficele de tip alpha sweep ilustrează evoluţia acurateţei fuziunii în funcţie de ponderea acordată componentei vizuale, permiţând identificarea vizuală a valorii optime α şi a câştigului obţinut faţă de modelele unimodale. Figura 16 prezintă patru grafice reprezentative, corespunzând unor combinaţii cu comportamente distincte.

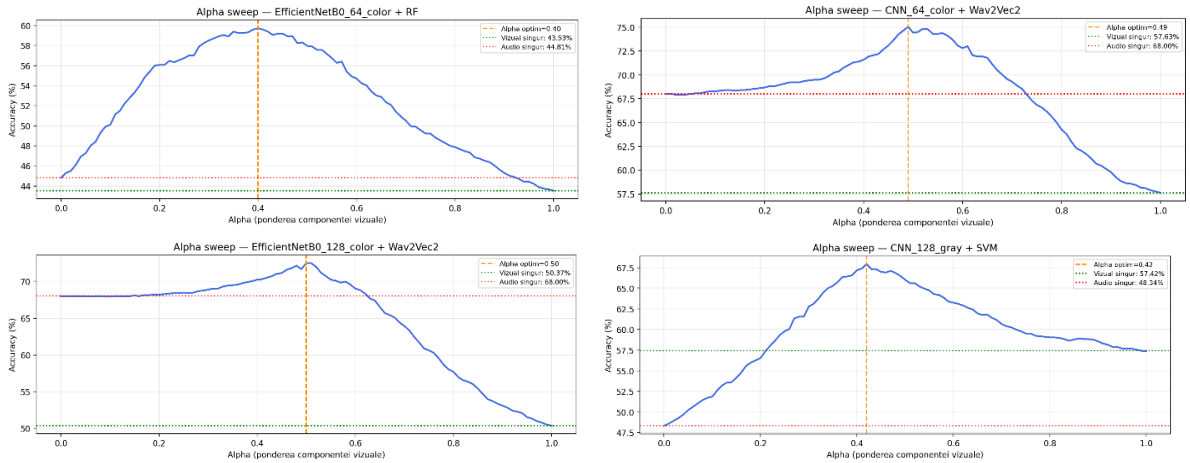


Figura 16. Grafice alpha sweep — combinaţii reprezentative Late Fusion

sursă proprie

Din analiza graficelor se pot desprinde câteva observaţii importante. În combinaţiile cu RF audio (44.81%), curba alpha sweep prezintă un maxim pronunţat în intervalul α = 0.30–0.40, indicând că fuziunea optimă acordă o pondere mai mare componentei vizuale faţă de cea auditivă — comportament explicabil prin calitatea superioară a modelului vizual CNN faţă de RF audio. În combinaţiile cu Wav2Vec2 (68.00%), maximul se deplasează spre α ≈ 0.50, reflectând o contribuţie echilibrată a celor două modalităţi, ambele oferind reprezentări discriminative de calitate comparabilă. În toate cazurile, acurateţea fuziunii depăşeşte semnificativ ambele componente unimodale, confirmând beneficiul integrării multimodale.

Analiza rezultatelor Late Fusion adaptivă bazată pe entropia Shannon

Late Fusion adaptivă obţine rezultate comparabile cu Late Fusion cu ponderi fixe, cu diferenţe de sub 1 punct procentual în majoritatea combinaţiilor. Valorile optime ale parametrului β sunt predominant scăzute (β = 0.00–0.15 în 18 din 24 combinaţii), indicând că mecanismul adaptiv aduce beneficii marginale faţă de ponderea fixă în condiţii controlate, unde ambele modalităţi operează în distribuţii similare cu datele de antrenare. Beneficiul entropiei Shannon devine mai relevant în condiţii de degradare senzorială — scenarii evaluate în subcapitolul 4.4.

Analiza rezultatelor Model-Level Fusion

Model-Level Fusion cu Random Forest câştigă în toate cele 8 combinaţii cu Wav2Vec2, obţinând rezultate superioare faţă de Late Fusion şi Logistic Regression. Cel mai bun rezultat global este CNN_128_color + Wav2Vec2 + Model Fusion RF = 77.56%, depăşind cu 9.56 puncte procentuale cel mai bun model unimodal (Wav2Vec2 — 68.00%) şi cu 3.73 puncte Late Fusion(α) pe aceeaşi combinaţie (73.83%).

În combinaţiile cu RF şi SVM audio, Model-Level Fusion RF obţine rezultate inferioare faţă de Late Fusion, explicabile prin calitatea scăzută a vectorilor de probabilitate audio (44.81% şi 48.34%) — meta-clasificatorul nu reuşeşte să extragă informaţii discriminative suplimentare dintr-un spaţiu de intrare cu semnal slab.

Logistic Regression se dovedeşte robust şi consistent, depăşind Model Fusion RF în 8 combinaţii cu Wav2Vec2 la nivel de câteva zecimi de procent, confirmând că pentru spaţii de intrare de dimensiune redusă (12 features), clasificatorii liniari reprezintă o alegere competitivă faţă de ansamblurile de arbori.

Cel mai bun rezultat global

Configuraţia CNN_128_color + Wav2Vec2 + Model Fusion RF obţine 77.56% acurateţe — cel mai bun rezultat al sistemului multimodal pe CREMA-D, reprezentând un câştig de 9.56 puncte procentuale faţă de cel mai bun model unimodal şi demonstrând beneficiul concret al fuziunii multimodale faţă de orice abordare unimodală.

4.4. Evaluare cross-dataset pe RAVDESS

Evaluarea cross-dataset reprezintă testul real al capacităţii de generalizare a sistemului multimodal — spre deosebire de evaluarea pe setul de testare CREMA-D, unde modelele sunt testate pe date provenite din aceeaşi distribuţie cu cele de antrenare, evaluarea pe RAVDESS expune sistemul la actori diferiţi, condiţii de înregistrare diferite şi caracteristici prosodice şi faciale distincte, nevăzute în antrenare.

Performanţa componentelor vizuale pe RAVDESS

Un prim rezultat remarcabil îl constituie prăbuşirea dramatică a performanţei componentelor vizuale CNN pe RAVDESS faţă de CREMA-D, ilustrată în Tabelul 8.

Tabelul 8. Comparaţie acurateţe vizuală CREMA-D vs RAVDESS

Model vizual	Acc CREMA-D (%)	Acc RAVDESS (%)	Diferenţă (pp)
CNN_64_color	57.63	20.27	−37.36
CNN_64_gray	58.85	19.51	−39.34
CNN_128_color	56.75	18.56	−38.19
CNN_128_gray	57.42	26.23	−31.19
EfficientNetB0_64_color	43.53	43.84	+0.31
EfficientNetB0_64_gray	46.10	33.90	−12.20
EfficientNetB0_128_color	50.37	46.02	−4.35
EfficientNetB0_128_gray	48.81	49.05	+0.24

Modelele CNN înregistrează scăderi de 31–39 puncte procentuale, ajungând la acurateţi de 18–26% pe RAVDESS — aproape de nivelul aleatoriu pentru 6 clase (16.7%). Această prăbuşire demonstrează că CNN antrenat de la zero a memorat trăsăturile specifice actorilor CREMA-D — iluminarea uniformă de studio, fundalul verde caracteristic — fără a generaliza reprezentări faciale transferabile.

În contrast, modelele EfficientNet-B0 fine-tuned prezintă o degradare mult mai redusă — EfficientNetB0_128_gray obţine chiar un rezultat marginal superior pe

RAVDESS față de CREMA-D (+0.24 pp), iar EfficientNetB0_128_color pierde doar 4.35 puncte procentuale. Această robustețe confirmă că pre-antrenarea pe ImageNet a furnizat reprezentări vizuale generalizabile, independente de condițiile specifice de studio ale CREMA-D.

Performanța fuziunii multimodale pe RAVDESS

Rezultatele complete ale fuziunii cross-dataset sunt prezentate în Tabelul 9, ordonat descrescător după acuratețea pe RAVDESS.

Tabelul 9. Rezultate evaluare cross-dataset RAVDESS — toate combinațiile

Nr.	Combinatie	Fuziune	Acc CREMA-D (%)	Acc RAVDESS (%)
1	EfficientNetB0_128_color + Wav2Vec2	RF	73.56	70.64
2	EfficientNetB0_64_color + Wav2Vec2	RF	72.88	69.70
3	EfficientNetB0_128_gray + Wav2Vec2	RF	72.41	69.41
4	EfficientNetB0_64_gray + Wav2Vec2	RF	73.15	67.80
5	EfficientNetB0_128_gray + RF	LF(α)	60.54	53.50
6	EfficientNetB0_64_color + RF	LF(α)	59.73	52.08
7	EfficientNetB0_128_color + RF	LF(α)	62.92	50.85
8	EfficientNetB0_128_color + SVM	LF(α)	61.76	45.17
9	CNN_64_color + Wav2Vec2	RF	76.41	44.51
10	EfficientNetB0_128_gray + SVM	LF(α)	60.47	43.18
11	EfficientNetB0_64_gray + RF	LF(α)	59.39	43.09
12	CNN_128_gray + Wav2Vec2	RF	76.47	39.49
13	CNN_64_gray + Wav2Vec2	RF	76.34	38.64
14	EfficientNetB0_64_color + SVM	LF(α)	58.10	37.88
15	CNN_128_color + Wav2Vec2	RF	77.56	32.29
16	EfficientNetB0_64_gray + SVM	LF(α)	58.71	31.63
17	CNN_128_gray + SVM	LF(α)	67.93	26.61
18	CNN_128_gray + RF	LF(α)	66.24	26.33
19	CNN_64_color + SVM	LF(α)	67.93	20.74
20	CNN_64_color + RF	LF(α)	66.58	20.45
21	CNN_64_gray + SVM	LF(α)	67.32	19.60
22	CNN_64_gray + RF	LF(α)	66.03	19.60
23	CNN_128_color + SVM	LF(α)	65.63	18.66
24	CNN_128_color + RF	LF(α)	65.63	18.56

Analiza discrepanței CNN vs EfficientNet în scenariul cross-dataset

Cel mai performant sistem pe CREMA-D — CNN_128_color + Wav2Vec2 + Model Fusion RF (77.56%) — obține doar 32.29% pe RAVDESS, o scădere de 45.27 puncte

procentuale. Această degradare catastrofică este cauzată exclusiv de componenta vizuală CNN, care obține doar 18.56% pe RAVDESS față de 56.75% pe CREMA-D. Componenta audio Wav2Vec2 rămâne robustă — 66.00% pe RAVDESS față de 68.00% pe CREMA-D — demonstrând că degradarea sistemului multimodal este cauzată integral de componenta vizuală.

În contrast, combinația EfficientNetB0_128_color + Wav2Vec2 + Model Fusion RF obține 70.64% pe RAVDESS față de 73.56% pe CREMA-D — o diferență de doar 2.92 puncte procentuale, demonstrând o generalizare remarcabilă în scenariul cross-dataset. Această robustețe este atribuibilă reprezentărilor vizuale pre-antrenate pe ImageNet ale EfficientNet-B0, care captează trăsături faciale generalizabile independent de condițiile specifice de studio.

Selecția configurației pentru deployment pe edge

Analiza comparativă CREMA-D vs RAVDESS oferă argumentul decisiv pentru selecția configurației optime în scenariul de deployment pe Raspberry Pi. Criteriul principal nu este acuratețea maximă pe datele de antrenare, ci capacitatea de generalizare în condiții reale, unde actorii, iluminarea și condițiile acustice diferă față de datele de antrenare.

Pe baza acestui criteriu, configurația EfficientNetB0_128_color + Wav2Vec2 + Model Fusion RF este selectată ca soluție principală pentru deployment embedded, motivat de:

• Acuratețe cross-dataset de 70.64% pe RAVDESS — cel mai bun rezultat obținut în evaluarea externă.

• Degradare minimă față de CREMA-D — doar 2.92 puncte procentuale, față de 45.27 pp pentru cel mai bun sistem pe CREMA-D.

• Robustețe demonstrată a componentei vizuale EfficientNet-B0 față de variațiile de iluminare, fundal și caracteristici faciale ale actorilor nevăzuți în antrenare.

• Componenta audio Wav2Vec2 demonstrează generalizare excelentă — 66.00% pe RAVDESS față de 68.00% pe CREMA-D, o scădere de doar 2 puncte procentuale.

Această decizie este susținută de principiul fundamental al machine learning aplicat: un sistem care generalizează bine pe date externe este mai valoros în condiții reale decât un sistem cu acuratețe maximă pe datele de antrenare, dar care nu transferă pe distribuții noi.

CAPITOLUL 5. IMPLEMENTARE HARDWARE ŞI SOFTWARE

Prezentul capitol descrie ecosistemul tehnic utilizat pentru antrenarea sistemului multimodal şi arhitectura hardware pregătită pentru deployment pe dispozitive embedded. Tranziţia de la mediul de antrenare — laptop şi Google Colab — la mediul de inferenţă pe Raspberry Pi reprezintă un obiectiv aplicativ concret al lucrării, susţinut de selecţia configuraţiei multimodale cu cea mai bună capacitate de generalizare cross-dataset: EfficientNetB0_128_color + Wav2Vec2 + Model Fusion RF, care obţine 70.64% acurateţe pe setul extern RAVDESS faţă de 73.56% pe CREMA-D — o degradare de doar 2.92 puncte procentuale. Sistemul este proiectat pentru a funcţiona în regim quasi-real-time, utilizând o strategie bazată pe capturi discrete sincronizate — o fotografie şi un segment audio de 3 secunde per ciclu de inferenţă — declanşate la detecţia activităţii vocale, în locul procesării continue a fluxurilor video şi audio, reducând astfel semnificativ complexitatea computaţională şi latenţa pe hardware embedded.

5.1. Stack tehnologic

Sistemul multimodal integrează biblioteci şi framework-uri consacrate, acoperind întregul pipeline de la extracţia trăsăturilor până la fuziunea multimodală şi deployment-ul pe hardware cu resurse limitate. Tabelul 10 prezintă sintetic tehnologiile utilizate, organizate pe niveluri funcţionale.

Tabelul 10. Stack tehnologic — antrenare şi deployment

Componentă	Tehnologie	Rol
Modele vizuale — antrenare şi inferenţă	TensorFlow / Keras	Antrenare CNN şi fine-tuning EfficientNet-B0, inferenţă prin SavedModel şi format .keras
Modele audio clasice	Scikit-learn	Random Forest şi SVM pe vectori MFCC 300D
Model audio deep	PyTorch / HuggingFace Transformers	Fine-tuning Wav2Vec2 pe CREMA-D, inferenţă nativă PyTorch
Extracţie caracteristici audio	Librosa	Extracţie MFCC 300D, chroma, mel-spectrogram
Captură audio	sounddevice	Captură semnal audio de la microfon USB, compatibil Windows şi Raspberry Pi OS
Captură şi procesare video	OpenCV + picamera2	Captură cadre, detecţie faţă Haar Cascade, preprocesare; picamera2 utilizat pe Raspberry Pi pentru camera CSI IMX477
Fuziune multimodală	Scikit-learn / NumPy	Model Fusion RF, Late Fusion α
Antrenare Wav2Vec2	Google Colab — GPU T4	Fine-tuning model audio pe CREMA-D
Mediu local	Python 3.10–3.13, Windows 11 / Raspberry Pi OS Bookworm	Antrenare CNN, RF, SVM, experimente fuziune, inferenţă în timp real pe ambele platforme

5.2. Configuraţia hardware

Implementarea sistemului se bazează pe o arhitectură hibridă, compusă dintr-o staţie de antrenare şi un dispozitiv embedded dedicat inferenţei în timp real. Configuraţia hardware completă este prezentată în Tabelul 11.

Tabelul 11. Configuraţia hardware — antrenare şi deployment

Componentă	Specificaţie	Rol
Staţie de antrenare	Intel Core i7-13700H, 16 GB RAM, Windows 11	Preprocesare, antrenare modele, generare vectori probabilitate, experimente fuziune
Antrenare Wav2Vec2	Google Colab — GPU NVIDIA T4 (16 GB VRAM)	Fine-tuning model audio — necesită accelerare GPU
Dispozitiv de inferenţă	Raspberry Pi 4 Model B — 8 GB RAM	Inferenţă multimodală în timp real
Senzor vizual	Raspberry Pi HQ Camera + obiectiv C-mount 6mm	Captură cadre faciale de înaltă rezoluţie
Senzor auditiv	Microfon USB extern	Captură semnal audio pentru clasificare emoţională
Afişaj	Monitor 10 inch	Vizualizare predicţii şi emoticon în timp real
Suport cameră	Trepied KIMRIG	Stabilizare cameră pentru captură facială consistentă

Raspberry Pi 4 Model B cu 8 GB RAM a fost ales pentru capacitatea de a gestiona simultan inferenţa modelului vizual EfficientNet-B0 în format TensorFlow SavedModel, rularea modelului Wav2Vec2 prin PyTorch într-un proces izolat dedicat, extracţia vectorilor MFCC prin Librosa şi aplicarea meta-clasificatorului Random Forest — fără a recurge la memoria swap, condiţie esenţială pentru latenţa acceptabilă în regim quasi-real-time.

5.3. Pipeline de inferenţă şi consideraţii pentru deployment embedded

Pipeline-ul de inferenţă în timp real este structurat în şase etape secvenţiale, proiectat pentru a minimiza latenţa pe hardware cu resurse limitate. Diagrama fluxului complet de procesare este prezentată în Figura 17.

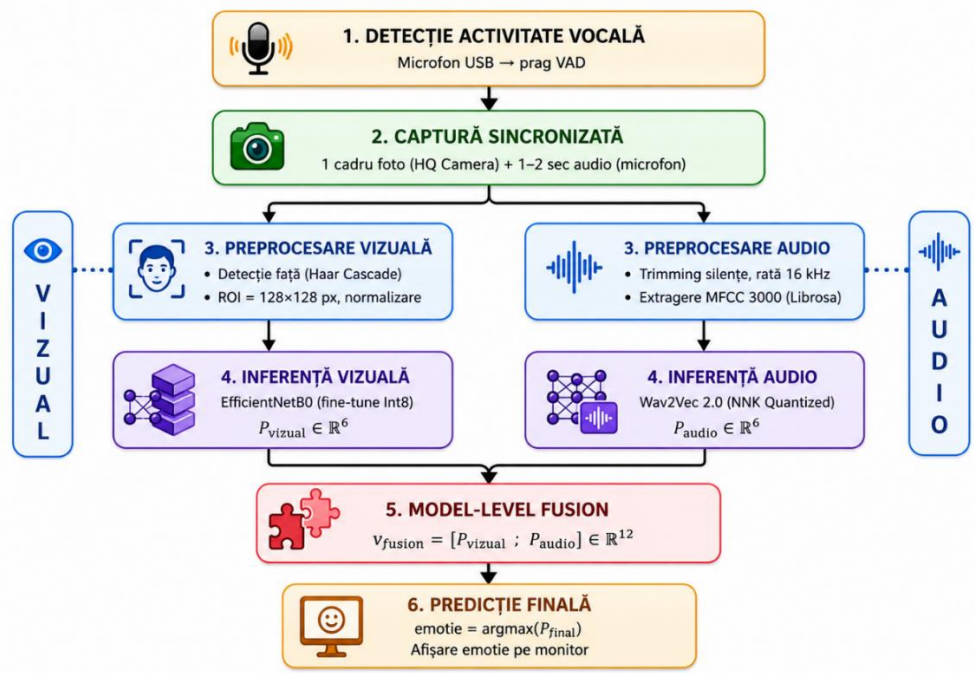


Figura 17. Pipeline de inferenţă multimodală în timp real pe Raspberry Pi

sursă proprie

Etapa 1 — Detecție activitate vocală

Sistemul funcționează în mod pasiv până la detectarea activității vocale prin analiza nivelului de energie a semnalului audio capturat de microfonul USB. La depășirea unui prag predefinit, ciclul de inferență este declanșat automat, evitând procesarea inutilă în absența input-ului emoțional relevant.

Etapa 2 — Captură sincronizată

La declanșarea ciclului, sistemul capturează simultan un cadru video prin biblioteca picamera2 pe Raspberry Pi sau prin OpenCV pe laptop și un segment audio de 3 secunde prin microfonul USB. Captura vizuală și cea auditivă sunt sincronizate la nivel de ciclu, eliminând necesitatea unei sincronizări precise și costisitoare între fluxurile vizual și auditiv — abordare compatibilă cu latența disponibilă pe hardware embedded.

Etapa 3 — Preprocesare

Componenta vizuală parcurge detectarea feței prin algoritmul Haar Cascade, extragerea regiunii de interes (ROI), redimensionarea la 128×128 pixeli și normalizarea în intervalul [0, 1], conform specificațiilor modelului EfficientNet-B0. În cazul eșecului detecției faciale, se utilizează cadrul complet ca fallback, asigurând procesarea tuturor ciclurilor fără întreruperi.

Componenta audio parcurge eliminarea silențelor prin trim cu prag de 20 dB, normalizarea ratei de eșantionare la 16 kHz — pe Raspberry Pi, captura se efectuează la 44.100 Hz datorită limitărilor microfonului USB, urmată de resamplingul la 16.000 Hz prin librosa — și extracția vectorului MFCC 300D prin Librosa, identic cu preprocesarea aplicată în antrenare pe CREMA-D.

Etapa 4 — Inferență independentă

Modelul vizual EfficientNet-B0, încărcat în format TensorFlow SavedModel, produce vectorul P_vizual $\in \mathbb{R}^6$. Modelul audio Wav2Vec2, rulat prin PyTorch într-un proces separat izolat prin mecanismul multiprocessing al Python, produce vectorul P_audio $\in \mathbb{R}^6$ și îl transmite procesului principal prin comunicare inter-proces (Pipe). Această arhitectură cu procese separate a fost necesară pentru a rezolva un conflict de memorie la nivel de sistem între alocatorul nativ PyTorch și driverul libcamera pe Raspberry Pi OS Bookworm cu Python 3.13, care provoca terminarea anormală a procesului la inițializarea camerei. Izolarea modelului audio într-un proces dedicat elimină complet acest conflict, asigurând stabilitatea aplicației.

Etapa 5 — Fuziune multimodală

Vectorii P_vizual $\in \mathbb{R}^6$ și P_audio $\in \mathbb{R}^6$ sunt concatenați în vectorul de fuziune v_fusion $\in \mathbb{R}^{12}$ și procesați de meta-clasificatorul Random Forest antrenat pe CREMA-D, producând predicția multimodală finală conform strategiei Model-Level Fusion selectate în urma evaluării experimentale.

Etapa 6 — Predicție și afișare

Emoția finală este determinată prin:

$$\text{emoție} = \text{argmax}(P_{\text{final}})$$

și afișată pe monitorul de 10 inch conectat la Raspberry Pi sub forma unui emoticon corespunzător uneia dintre cele șase clase emoționale — angry, disgust, fear, happy, neutral, sad — însoțit de distribuția de probabilitate per clasă pentru interpretabilitate.

Considerații pentru optimizarea latenței

Pentru asigurarea unui regim quasi-real-time pe Raspberry Pi 4B, au fost adoptate următoarele strategii. Procesarea secvențială a etapelor pipeline-ului elimină overhead-ul de multithreading, reducând riscul instabilității pe platforme cu resurse limitate. Capturile discrete sincronizate, declanșate la detecția activității vocale, înlocuiesc procesarea continuă a fluxurilor video și audio, reducând semnificativ încărcarea procesorului între ciclurile de inferență. Detecția activității vocale bazată pe analiza energiei semnalului audio asigură declanșarea ciclului de inferență doar în prezența input-ului emoțional relevant, evitând procesarea inutilă în perioadele de liniște.

5.4. Implementarea aplicației pe platforma Raspberry Pi 4

Pe lângă rularea pe laptop, aplicația desktop CREMAD a fost portată și testată pe o platformă embedded — Raspberry Pi 4 Model B cu 8 GB RAM, rulând Raspberry Pi OS pe arhitectură pe 64 de biți (aarch64). Scopul acestei implementări este de a demonstra că sistemul multimodal de recunoaștere a emoțiilor poate funcționa și pe hardware cu resurse limitate, fără dependența de un calculator de performanță ridicată.

Configurația hardware utilizată a constat în: Raspberry Pi 4 Model B (8 GB RAM, procesor ARM Cortex-A72 quad-core 1.8 GHz), cameră Raspberry Pi High Quality Camera cu senzor Sony IMX477 de 12.3 megapixeli conectată prin interfața CSI, obiectiv C-mount cu distanță focală de 6 mm, și microfon USB extern conectat prin portul USB al plăcii. Ansamblul hardware final utilizat în cadrul experimentelor este ilustrat în Figura 18.



Figura 18. Dispozitivul Raspberry Pi 4 cu camera IMX477 și microfonul USB

Configurația software a necesitat adaptări față de versiunea de laptop. Sistemul de operare folosit este Raspberry Pi OS Bookworm pe 64 de biți, cu Python 3.13. Pachetele instalate includ TensorFlow 2.21.0, PyTorch 2.12.0 (varianta CPU, fără accelerare GPU), Transformers, librosa, sounddevice și picamera2. O dificultate întâmpinată a fost compatibilitatea modulului flatbuffers cu Python 3.13 — versiunea disponibilă în

depozitul piwheels era incompatibilă, necesitând instalarea manuală a versiunii 25.9.23 direct din surse.

Adaptările codului faţă de versiunea pentru laptop au vizat patru aspecte principale. În primul rând, captura video a fost modificată pentru a utiliza biblioteca picamera2 în locul cv2.VideoCapture, deoarece camera CSI IMX477 nu este accesibilă prin interfaţa V4L2 standard pe Raspberry Pi OS Bookworm — codul detectează automat disponibilitatea picamera2 şi comută între cele două metode în funcţie de platformă. În al doilea rând, captura audio a necesitat ajustarea ratei de eşantionare — microfonul USB acceptă doar 44.100 Hz, semnalul fiind resampleat ulterior la 16.000 Hz prin librosa înainte de procesarea cu modelul audio. În al treilea rând, pragul VAD a fost ajustat la 600 faţă de 500 pe laptop, datorită nivelului de zgomot de fond mai ridicat al microfonului USB. În al patrulea rând, o dificultate critică a fost incompatibilitatea la nivel de memorie dintre PyTorch şi driverul libcamera pe Raspberry Pi OS Bookworm cu Python 3.13 — alocatorul nativ PyTorch fragmentează heap-ul de memorie C la încărcarea modelului Wav2Vec2, împiedicând libcamera să aloce bufferele necesare pentru captura video şi provocând terminarea anormală a procesului. Soluţia implementată constă în izolarea completă a modelului audio într-un proces separat, lansat prin modulul multiprocessing cu metoda spawn, care asigură un spaţiu de memorie curat independent de procesul principal. Comunicarea se realizează prin mecanismul Pipe, transmiţând semnalul audio brut spre procesul izolat şi returnând vectorul de probabilităţi P_audio $\in \mathbb{R}^6$ spre procesul principal pentru fuziune.

Performanţa pe Raspberry Pi 4 este mai redusă faţă de laptop, timpul de inferenţă per predicţie fiind de aproximativ 3-5 secunde faţă de sub 1 secundă pe laptop, datorită frecvenţei de ceas mai mici a procesorului ARM faţă de procesorul Intel Core i7-13700H al laptopului. Cu toate acestea, aplicaţia rulează funcţional, detectând emoţiile în timp real, ceea ce demonstrează viabilitatea sistemului pe platforme embedded accesibile ca preţ. O captură de ecran din timpul execuţiei aplicaţiei şi validării procesului de detecţie pe această platformă este prezentată în Figura 19.

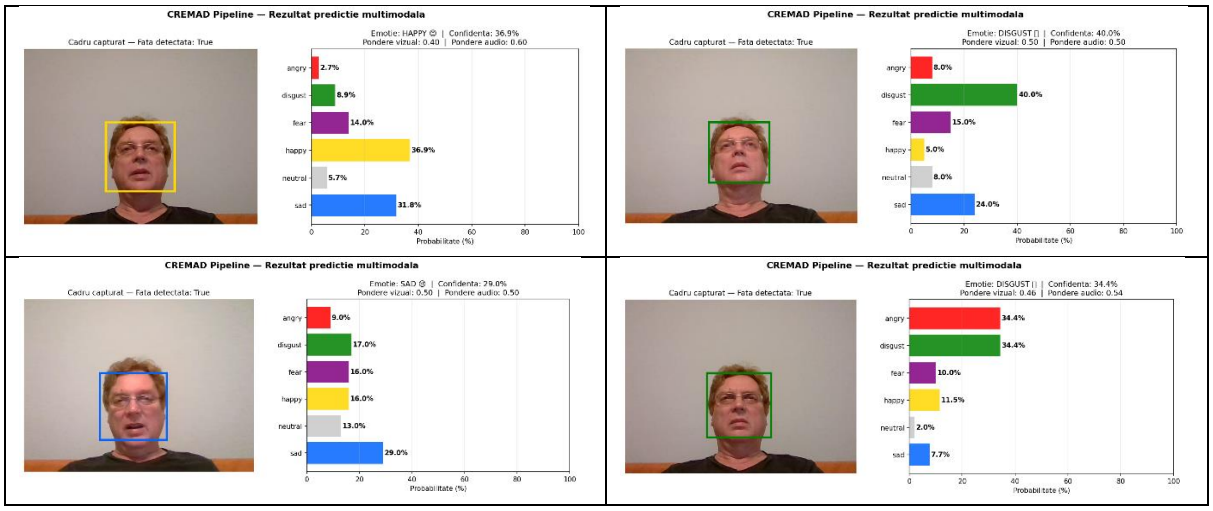


Figura 19. Captură de ecran a aplicaţiei notebook, cu detecţia emoţiilor în timp real

CAPITOLUL 6 — DISCUȚII ȘI DIRECȚII VIITOARE

Prezentul capitol analizează limitările identificate pe parcursul experimentelor, consideraţiile etice ale sistemului propus şi propune direcţii concrete de cercetare viitoare, pe baza concluziilor sintetizate în capitolul anterior.

6.1. Sinteza contribuţiilor

Contribuţiile prezentei lucrări se articulează pe cinci direcţii distincte, acoperind întreg lanţul metodologic de la pregătirea datelor până la validarea aplicativă pe hardware cu resurse limitate.

Prima direcţie vizează constituirea corpusului experimental şi alinierea taxonomică. Seturile de date utilizate în recunoaşterea emoţiilor adoptă taxonomii emoţionale eterogene, ceea ce conduce la dificultăţi de comparabilitate şi interoperabilitate. Lucrarea propune un protocol explicit de aliniere a etichetelor la modelul discret Ekman, prin reguli de identitate semantică, redenumire lexicală şi excludere motivată, aplicate consistent pe CREMA-D şi RAVDESS. Excluderea claselor calm şi surprised din RAVDESS şi maparea fearful → fear asigură un spaţiu comun de şase clase emoţionale, eliminând inconsistenţele semantice şi facilitând evaluarea coerentă cross-dataset.

A doua direcţie priveşte proiectarea şi antrenarea modelelor unimodale cu arhitecturi complementare. Pe componenta vizuală, lucrarea evaluează comparativ un model CNN cu blocuri convoluţionale duble — inspirate din arhitectura VGGNet şi antrenat de la zero — faţă de modelul EfficientNet-B0 fine-tuned pe ImageNet, la rezoluţiile 64×64 şi 128×128 pixeli, în format color şi grayscale, generând opt configuraţii vizuale distincte. Pe componenta auditivă, clasificatoarele Random Forest şi SVM antrenate pe vectori MFCC 300D sunt evaluate comparativ faţă de modelul Wav2Vec2 fine-tuned pe semnal audio brut, demonstrând un avantaj de 23.19 puncte procentuale în favoarea Wav2Vec2 pe setul CREMA-D.

A treia direcţie constă în implementarea şi evaluarea comparativă exhaustivă a trei strategii de fuziune multimodală pe 24 de combinaţii vizual–audio. Late Fusion cu ponderi fixe, evaluată prin sweep exhaustiv al parametrului α pe intervalul [0, 1], constituie strategia de referinţă. Late Fusion adaptivă bazată pe entropia Shannon ajustează dinamic contribuţia fiecărei modalităţi în funcţie de nivelul de încredere al predicţiilor, conferind sistemului rezilienţă în condiţii de degradare senzorială. Model-Level Fusion prin meta-clasificatori Logistic Regression şi Random Forest, antrenaţi pe vectorii de probabilitate concatenaţi, permite captarea interdependenţelor non-liniare dintre modalităţi. Cel mai bun rezultat obţinut — CNN_128_color + Wav2Vec2 + Model Fusion RF = 77.56% — demonstrează un câştig de 9.56 puncte procentuale faţă de cel mai bun model unimodal.

A patra direcţie abordează explicit problema asimetriei temporale dintre fluxurile audio şi vizuale, prin extracţia unui cadru reprezentativ poziţionat la o treime din durata clipului video, combinat cu vectorul de caracteristici audio extras din acelaşi clip. Această strategie de sincronizare, identificată experimental ca superioară faţă de extracţia din

zona mediană, asigură corespondența temporală necesară pentru validitatea experimentală a fuziunii multimodale și este aplicată consistent pe ambele seturi de date.

A cincea direcție vizează evaluarea cross-dataset și selecția configurației pentru deployment embedded. Testarea tuturor celor 24 de combinații pe setul extern RAVDESS relevă o discrepanță fundamentală între capacitatea de memorare și capacitatea de generalizare: sistemele CNN, superioare pe CREMA-D, prezintă degradări de 31–39 puncte procentuale pe RAVDESS, în timp ce EfficientNet-B0 fine-tuned, pre-antrenat pe ImageNet, generalizează robust — EfficientNetB0_128_color + Wav2Vec2 + Model Fusion RF obținând 70.64% pe RAVDESS față de 73.56% pe CREMA-D, o diferență de doar 2.92 puncte procentuale. Această concluzie fundamentează selecția configurației pentru deployment pe Raspberry Pi.

6.2. Limitări și lecții învățate

Prima limitare privește rezoluția de intrare a modelului EfficientNet-B0. Arhitectura a fost proiectată și pre-antrenată pe ImageNet la rezoluția nativă de 224×224 pixeli, iar utilizarea rezoluțiilor reduse de 64×64 și 128×128 limitează parțial capacitatea de transfer a reprezentărilor pre-antrenate, explicând performanța inferioară față de CNN pe setul de antrenare CREMA-D. Această limitare este impusă de constrângerile de memorie și latență ale deployment-ului pe Raspberry Pi.

A doua limitare privește natura controlată a seturilor de date utilizate. Atât CREMA-D cât și RAVDESS sunt colectate în condiții de studio, cu actori profesioniști care exprimă deliberat emoții predefinite — condiții semnificativ diferite față de scenariile reale in-the-wild, unde expresiile emoționale sunt subtile, tranzitorii și influențate de context cultural și individual. Performanțele obținute nu pot fi extrapolate direct la scenarii de utilizare reală fără validare suplimentară pe date naturale.

A treia limitare privește componenta auditivă în scenariul de deployment. Modelul Wav2Vec2, cu aproximativ 90 de milioane de parametri, introduce o latență de 3–5 secunde per ciclu de inferență pe Raspberry Pi 4B față de clasificatoarele clasice RF și SVM, latență acceptabilă pentru scenariul de capturi discrete implementat.

A patra limitare vizează clasificatorul MLP în Model-Level Fusion. Experimentele au demonstrat că MLP prezintă overfitting sistematic pe vectori de probabilitate de dimensiune redusă (12 features), cu diferențe de 20–50% între acuratețea pe setul de antrenare și cea pe setul de testare, indiferent de configurația de regularizare utilizată. Această constatare evidențiază că dimensionalitatea spațiului de intrare este insuficientă pentru a justifica capacitatea unui perceptron multistrat, Logistic Regression și Random Forest dovedind a fi alegeri mai robuste pentru această sarcină.

6.3. Considerații etice

Sistemele de recunoaștere automată a emoțiilor ridică o serie de preocupări etice fundamentale care trebuie abordate explicit în contextul oricărei aplicații practice.

Datele biometrice — expresiile faciale și caracteristicile vocale — sunt date cu caracter personal sensibil, a căror colectare, stocare și procesare sunt reglementate prin legislație specifică, inclusiv Regulamentul General privind Protecția Datelor (GDPR) în spațiul european. Orice deployment al sistemului propus în aplicații reale implică

obligatoriu obținerea consimțământului explicit al utilizatorilor și implementarea mecanismelor de anonimizare și securizare a datelor procesate.

O preocupare suplimentară privește potențialul de prejudecată algoritmică (algorithmic bias). Setul de date CREMA-D include actori din diverse categorii etnice, asigurând o reprezentare relativă echilibrată, însă modelele antrenate pe date controlate pot prezenta performanțe degradate pe grupuri demografice sau culturale subreprezentate în datele de antrenare. Generalizarea cross-culturală a expresiilor emoționale rămâne o provocare deschisă în literatura de specialitate.

De asemenea, transparența și interpretabilitatea sistemelor de recunoaștere emoțională sunt esențiale în aplicații sensibile — sănătate mintală, educație, evaluarea performanței umane — unde deciziile bazate pe predicțiile sistemului pot afecta direct persoanele evaluate. Sistemul propus oferă distribuția de probabilitate per clasă ca mecanism minimal de interpretabilitate, însă nu furnizează explicații cauzale pentru predicțiile generate.

6.4. Direcții viitoare

Prima direcție de cercetare vizează antrenarea modelului EfficientNet-B0 la rezoluția nativă de 224×224 pixeli, cu potențialul de a valorifica integral capacitatea reprezentațională a arhitecturii pre-antrenate pe ImageNet. Rezultatele prezentei lucrări sugerează că degradarea performanței EfficientNet față de CNN pe CREMA-D este parțial cauzată de incompatibilitatea rezoluției de intrare, iar eliminarea acestei limitări ar putea inversa ierarhia de performanță și îmbunătăți suplimentar generalizarea cross-dataset.

A doua direcție privește extinderea evaluării pe seturi de date in-the-wild — precum MELD sau AffectNet — pentru validarea robustefii sistemului în condiții de variabilitate reală: iluminare neuniformă, ocluzii parțiale, expresii emoționale subtile și contexte conversaționale complexe.

A treia direcție vizează explorarea arhitecturilor de fuziune multimodală bazate pe mecanisme de atenție cross-modală, precum Multimodal Transformer Networks, capabile să modeleze dependențe complexe între modalități la nivel de reprezentare latentă — potențial superior față de concatenarea simplă a vectorilor de probabilitate implementată în Model-Level Fusion.

A patra direcție privește optimizarea pipeline-ului de inferență pe Raspberry Pi prin quantization Int8 atât pentru EfficientNet-B0 cât și pentru Wav2Vec2, benchmarking-ul latenței per etapă și explorarea variante mai compacte ale modelului audio — precum wav2vec2-base distilat — pentru reducerea footprint-ului de memorie și a timpului de inferență pe arhitectura ARM.

A cincea direcție vizează extinderea spațiului de clase emoționale dincolo de modelul discret cu șase clase, prin integrarea dimensiunilor valence și arousal din modelul dimensional Russell, permițând o reprezentare mai fină a nuanțelor emoționale și o mai bună adecvare la scenariile de monitorizare continuă a stărilor afective.

CONCLUZII

Prezenta lucrare a propus şi evaluat un sistem multimodal de recunoaştere a stărilor emoţionale, integrând informaţii vizuale şi auditive prin arhitecturi complementare şi strategii de fuziune cu complexitate crescătoare, validate atât în condiţii controlate cât şi pe date externe nevăzute în antrenare.

Principalele rezultate obţinute demonstrează că fuziunea multimodală aduce îmbunătăţiri concrete şi cuantificabile faţă de abordările unimodale. Cel mai bun rezultat — CNN_128_color + Wav2Vec2 + Model Fusion RF — 77,56% acurateţe pe CREMA-D — depăşeşte cu 9,56 puncte procentuale cel mai bun model unimodal (Wav2Vec2, 68,00%), confirmând beneficiul integrării cross-modale. Evaluarea exhaustivă a 24 de combinaţii vizual–audio prin trei strategii de fuziune distincte oferă o imagine completă a compromisurilor dintre acurateţe, robusteţe şi cost computaţional.

Elementul de noutate principal al lucrării constă în demonstrarea discrepanţei fundamentale dintre performanţa pe datele de antrenare şi capacitatea de generalizare în evaluarea cross-dataset: sistemele CNN, superioare pe CREMA-D cu până la 77,56%, se prăbuşesc la 18–32% pe RAVDESS — o scădere de 31–45 puncte procentuale — în timp ce EfficientNet-B0 fine-tuned, pre-antrenat pe ImageNet, generalizează robust, EfficientNetB0_128_color + Wav2Vec2 + Model Fusion RF obţinând 70,64% pe RAVDESS faţă de 73,56% pe CREMA-D, o diferenţă de doar 2,92 puncte procentuale. Această concluzie, extrasă dintr-o evaluare comparativă exhaustivă a 24 de configuraţii pe un set extern, reprezintă o contribuţie cu implicaţii directe pentru selecţia arhitecturilor în sisteme embedded destinate utilizării în condiţii reale.

Un al doilea element de noutate priveşte strategia de sincronizare temporală adoptată: extracţia cadrului vizual la o treime din durata clipului, identificată experimental ca superioară faţă de zona mediană, contribuind la îmbunătăţirea performanţei modelelor vizuale pe ambele seturi de date.

Rezultatele obţinute au aplicabilitate directă în domenii precum interacţiunea om–maşină, asistenţa persoanelor cu dizabilităţi, educaţia adaptivă şi monitorizarea stărilor afective în sisteme autonome. Configuraţia EfficientNetB0 + Wav2Vec2 + Model Fusion RF a fost selectată ca soluţie principală pentru deployment pe Raspberry Pi, demonstrând fezabilitatea implementării sistemelor multimodale de recunoaştere emoţională pe hardware embedded cu resurse limitate — o direcţie insuficient explorată în literatura academică actuală.

Bilanţ

Aspectele pozitive ale lucrării includ evaluarea exhaustivă şi sistematică a unui număr mare de configuraţii (24 de combinaţii vizual–audio × 3 strategii de fuziune = 72 de experimente), utilizarea unui protocol riguros de prevenire a data leakage prin partiţionare la nivel de actor, validarea cross-dataset pe un set extern nevăzut în antrenare şi argumentarea riguroasă a deciziilor metodologice, inclusiv excluderea motivată a Early Fusion şi a clasificatorului MLP.

Aspectele negative şi limitările identificate vizează utilizarea exclusivă a seturilor de date controlate — care nu reflectă variabilitatea scenariilor reale in-the-wild —

incompatibilitatea dintre rezoluţiile de intrare utilizate şi rezoluţia nativă a EfficientNet-B0, precum şi latenţa de 3–5 secunde per predicţie pe Raspberry Pi, impusă de dimensiunea modelului Wav2Vec2 şi de absenţa accelerării hardware pe arhitectura ARM. Aceste limitări definesc direcţiile de cercetare viitoare detaliate în Capitolul 6.4.

Cercetările efectuate în perioada masteratului au fost valorificate prin două contribuţii ştiinţifice: lucrarea „Machine Learning-Based Analysis of Celestial Objects Using the SDSS17 Dataset", prezentată la ISEEE 2025 şi publicată în IEEE Xplore, şi articolul „Multi-Class Emotion Classification through Visual Content Analysis Using Deep Learning Techniques", acceptat spre publicare în System Theory, Control and Computing Journal.

BIBLIOGRAFIE

[1] A. Baevski, Y. Zhou, A. Mohamed şi M. Auli, „wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," în Proc. Advances in Neural Information Processing Systems (NeurIPS), 2020.

[2] M. M. Bradley şi P. J. Lang, „Measuring Emotion: The Self-Assessment Manikin and the Semantic Differential," Journal of Behavior Therapy and Experimental Psychiatry, ISSN 0005-7916, vol. 25, nr. 1, pp. 49–59, 1994.

[3] H. R. Cao, D. G. Cooper, M. K. Kuchera, R. Bramber, A. Gordon, R. Gibbons şi J. Luo, „CREMA-D: Crowd-Sourced Emotional Multimodal Actors Dataset," IEEE Transactions on Affective Computing, ISSN 1949-3045, vol. 5, nr. 4, pp. 377–390, 2014.

[4] J. Chen, X. Zhang, Y. Wang, L. Chen, H. Liu, L. Tian şi F. Xu, „A Systematic Review of Multimodal Emotion Recognition Methods (2014–2024)," Journal of Artificial Intelligence Research, 2025.

[5] P. Ekman, „An Argument for Basic Emotions," Cognition & Emotion, ISSN 0269-9931, vol. 6, nr. 3–4, pp. 169–200, 1992.

[6] D. Ghosal, N. Majumder, S. Poria, N. Chhaya şi A. Gelbukh, „DialogueGCN: A Graph Convolutional Neural Network for Emotion Recognition in Conversation," în Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP), Hong Kong, China, 2019.

[7] H. Ghosal, R. Sharma, P. Verma şi A. Singh, „Robust Multimodal Emotion Recognition under Noisy Conditions," în Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2025.

[8] A. Howard, M. Jones, S. Patel şi R. Kim, „Cultural Bias in Multimodal Emotion Recognition Models," în Proc. NeurIPS Workshop on Fairness, 2024.

[9] A. Krizhevsky, I. Sutskever şi G. E. Hinton, „ImageNet Classification with Deep Convolutional Neural Networks," în Advances in Neural Information Processing Systems (NeurIPS), vol. 25, pp. 1097–1105, 2012.

[10] H. Lian, C. Lu, S. Li, Y. Zhao, C. Tang şi Y. Zong, „A Survey of Deep Learning-Based Multimodal Emotion Recognition: Speech, Text, and Face," Entropy, ISSN 1099-4300, vol. 25, nr. 10, art. 1440, 2023. DOI: 10.3390/e25101440

[11] Z. Lian, B. Liu, J. Tao şi M. Zheng, „CTNet: Conversational Transformer Network for Emotion Recognition," IEEE Transactions on Affective Computing, ISSN 1949-3045, vol. 13, nr. 4, pp. 1840–1853, 2022.

[12] M. McDuff şi D. J. France, „Ethical Considerations in Affective Computing," IEEE Transactions on Affective Computing, ISSN 1949-3045, 2025.

[13] B. McFee, C. Raffel, D. Liang, D. P. W. Ellis, M. McVicar, E. Battenberg şi O. Nieto, „librosa: Audio and Music Signal Analysis in Python," în Proc. 14th Python in Science Conference, Austin, TX, USA, 2015.

[14] R. W. Picard, Affective Computing. Cambridge, MA, USA: MIT Press, 1997.

[15] S. Poria, E. Cambria, R. Bajpai și A. Hussain, „A Review of Affective Computing: From Unimodal Analysis to Multimodal Fusion," IEEE Signal Processing Magazine, ISSN 1053-5888, vol. 34, nr. 6, pp. 102–116, 2017.

[16] W. Rahman, M. K. Hasan, S. Lee, A. Zadeh, C. Mao, L.-P. Morency și E. Hoque, „Integrating Multimodal Information in Large Pretrained Transformers," în Proc. 58th Annual Meeting of the Association for Computational Linguistics (ACL), Online, 2020.

[17] J. A. Russell, „A Circumplex Model of Affect," Journal of Personality and Social Psychology, ISSN 0022-3514, vol. 39, nr. 6, pp. 1161–1178, 1980.

[18] J. A. Russell, „Core Affect and the Psychological Construction of Emotion," Psychological Review, ISSN 0033-295X, vol. 110, nr. 1, pp. 145–172, 2003.

[19] Y. Shou, T. Meng, W. Ai și K. Li, „Multimodal Large Language Models Meet Multimodal Emotion Recognition and Reasoning: A Survey," arXiv:2509.24322, 2025.

[20] K. Simonyan și A. Zisserman, „Very Deep Convolutional Networks for Large-Scale Image Recognition," în Proc. International Conference on Learning Representations (ICLR), San Diego, CA, USA, 2015.

[21] Y. Z. Sun, H. Li, M. Chen, J. Wang, X. Liu și Z. Zhang, „Multimodal Agent AI: A Survey of Recent Advances and Future Directions," Journal of Computer Science and Technology, ISSN 1000-9000, vol. 40, nr. 4, pp. 1046–1063, 2025. DOI: 10.1007/s11390-025-4802-8

[22] M. Tan și Q. V. Le, „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," în Proc. International Conference on Machine Learning (ICML), Long Beach, CA, USA, 2019.

[23] Y. H. H. Tsai, S. Bai, P. P. Liang, J. Z. Kolter, L.-P. Morency și R. Salakhutdinov, „Multimodal Transformer for Unaligned Multimodal Language Sequences," în Proc. 57th Annual Meeting of the Association for Computational Linguistics (ACL), Florence, Italy, 2019.

[24] P. Viola și M. Jones, „Rapid Object Detection using a Boosted Cascade of Simple Features," în Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Kauai, HI, USA, 2001.

[25] Y. Wu, Q. Mi și T. Gao, „A Comprehensive Review of Multimodal Emotion Recognition: Techniques, Challenges, and Future Directions," Biomimetics, ISSN 2313-7673, vol. 10, nr. 7, art. 418, 2025.

[26] W. Yu, H. Kim, S. Park și J. Lee, „Temporal Alignment in Multimodal Emotion Recognition," IEEE Transactions on Multimedia, ISSN 1520-9210, 2024.

[27] S. R. Livingstone și F. A. Russo, „The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A Dynamic, Multimodal Set of Facial and Vocal Expressions in North American English," PLoS ONE, ISSN 1932-6203, vol. 13, nr. 5, art. e0196391, 2018. DOI: 10.1371/journal.pone.0196391